

Mestrado Profissional em Avaliação e
Monitoramento de Políticas Públicas

Métodos Quantitativos I

Aula 3: Testando hipóteses

Professores: Daniel Grimaldi e Arthur Bragança

3º Trimestre - 2025

Conceitos básicos

Inferência estatística

Teste de hipótese é o procedimento padrão para inferência estatística

- ❖ Na prática, ele é um procedimento que busca combinar a informação contida em um conjunto de dados observados com nosso conhecimento estatístico a respeito de distribuições téoricas (como as que vimos na aula anterior) para aprendermos sobre a realidade.
- ❖ Existem duas abordagens clássicas para inferência estatística: clássica e bayesiana
- ❖ Nossa aula se concentrará sobre a abordagem clássica - que se baseia na ideia de identificar alguns parâmetros populacionais verdadeiros.

Construindo a hipótese

- ❖ O primeiro passo é construir uma hipótese que seja **falseável sob uma perspectiva estatística**
- ❖ Na abordagem clássica, isso significa três coisas:
 - i. Definir um parâmetro (ou conjunto de parâmetros) de interesse;
 - ii. Definir uma hipótese a respeito do valor assumido pelo(s) parâmetro(s); e
 - iii. Definir uma hipótese a respeito da distribuição probabilística desse(s) parâmetro(s)
- ❖ O item ii. estabelece uma **hipótese nula** (H_0), e o item iii. me permite testá-la.

Testando a hipótese

- Após a definição da hipótese nula, podemos (por conta de iii.) definir uma **região crítica** para o parâmetro de interesse
 - i.e: um intervalo de valores que, se observados empiricamente, tornam a nossa H_0 altamente improvável
- O teste, então, passa ser conseguir uma amostra de dados que nos permita estimar o nosso(s) parâmetro(s)
 - se o valor estimado estiver na região crítica, então devemos a **rejeitar nossa H_0**

Exemplo: Renda informal de beneficiários do PBV

- ❖ Quero testar se a renda média informal dos beneficiários do Programa Bolsa Verde (μ_y) é igual a um determinado valor (μ_0): $H_0 : \mu_y = \mu_0$
- ❖ Consigo, então uma amostra (Y_1, Y_2, \dots, Y_n) para a renda dos beneficiários do PBF
- ❖ Se H_0 estiver correta, pelo TLC, vale que em grandes amostras:

$$\sqrt{n} \frac{\bar{\mu}_y - \mu_0}{\hat{\sigma}_{\bar{Y}}} \sim N(0, 1) \quad (1)$$

Região crítica

- ❖ A estatística apresentada em (1) é também conhecida como **estatística t** . Ela é uma das mais utilizadas em econometria. Se $t \sim N(0, 1)$, então:
 - ❖ $P(-1,96 \leq t \leq 1,96) = 95\%$
 - ❖ $P(-2,576 \leq t \leq 2,576) = 99\%$
- ❖ Ou seja, conforme o módulo da estatística t se afasta de 0, nossa H_0 se torna cada vez mais improvável.
 - ❖ A partir de um certo ponto, t se torna tão improvável que a única conclusão possível é que H_0 deve ser rejeitada
 - ❖ Chamamos de **região crítica** esse conjunto de valores que, quando observados, nos fazem rejeitar H_0

Erro tipo I

- ❖ Note que valor de t dentro da região crítica (qualquer que seja ela), não significa que H_0 é impossível, apenas que é improvável
- ❖ Portanto, sempre existe a possibilidade de rejeitarmos H_0 mesmo sendo ela verdadeira
- ❖ Chamamos essa possibilidade de Erro Tipo I, e podemos atribuir uma probabilidade a ele

$$P(\text{rejeitar } H_0 | H_0 \text{ é verdadeira}) = \alpha$$

Nível de significância

- Imagine que $|t| \geq 1,96$ caracteriza a região crítica para o nosso teste. Então vale que:

$$\begin{aligned}\alpha &= P(|t| \geq 1,96 \mid \mu_y = \mu) \\ &= 1 - P(|t| \leq 1,96 \mid \mu_y = \mu) \\ &= 5\%\end{aligned}\tag{2}$$

- α é também chamado de **nível de significância** (ou tamanho) do teste.
 - equivale ao grau de tolerância ao Erro do tipo I

Intervalo de confiança

- ❖ O conjunto de valores para os quais “toleramos” H_0 é o complementar da região crítica
- ❖ Esse intervalo dentro do qual confiamos em H_0 é denominado intervalo de confiança.
 - ❖ Ele depende diretamente do nível de significância que estabelecermos para o teste
- ❖ No nosso exemplo, dado um nível de significância de 5%, o intervalo de confiança é dado por:

$$[\mu_0 - 1,96 \hat{\sigma}_{\bar{y}}, \mu_0 + 1,96 \hat{\sigma}_{\bar{y}}]$$

p-valor

- ❖ No nosso exemplo, suponha que tenhamos observado um valor t_i para a estatística t .
- ❖ Ao invés de definirmos diretamente um nível de significância, podemos calcular a **probabilidade de observarmos um valor igual ou mais extremo do t_i sendo H_0 verdadeira**. Chamamos essa probabilidade de **p-valor**
- ❖ Em um teste bicaudal, isso equivale a calcularmos $P(|t| \geq t_i)$

Erro Tipo II

- ❖ É também verdade que observar valores “toleráveis” para t , não quer dizer que H_0 seja verdadeira.
 - ❖ Outras hipóteses diferentes de H_0 também podem produzir valores de t dentro da **região de aceitação de H_0**
- ❖ Por isso, existe também a possibilidade de não rejeitarmos H_0 , mesmo sendo H_0 falsa.
 - ❖ só pode ser calculado para uma hipótese alternativa definida
- ❖ Chamamos essa possibilidade de Erro Tipo II, cuja probabilidade é dada por:

$$P(\text{aceitar } H_0 | H_1 \text{ é verdadeira}) = \beta(H_1)$$

Poder do teste

- ❖ Chamamos de **poder do teste** a probabilidade de rejeitar H_0 quando H_0 é falsa. É equivalente a $1 - \beta(H_1)$
 - ❖ Teste não viesado: $1 - \beta \geq \alpha \forall \mu_0$;
 - ❖ Teste consistente: $\lim(1 - \beta)_{n \rightarrow \infty} = 1$
- ❖ Como regra geral, um teste vai ser não-viesado (consistente) se estiver baseado em um estimador não-viesado (consistente)

Estimador não-viesado

- ✚ $\hat{\theta}$ é não-viesado $\Leftrightarrow E(\hat{\theta}) = \theta$. Isso equivale dizer que o valor esperado do estimador equivale ao valor do parâmetro que se deseja estimar.
- ✚ Por exemplo, a média amostral (\bar{Y}) é um estimador não-viesado da média populacional (μ_y).

$$\begin{aligned} E(\bar{Y}) &= E\left(\frac{Y_1 + Y_2 + \dots + Y_N}{N}\right) \\ &= \frac{E(Y_1 + Y_2 + \dots + Y_N)}{N} \\ &= \frac{N\mu_y}{N} \end{aligned} \tag{3}$$

Estimador consistente

- ❖ $\hat{\theta}$ é consistente $\Leftrightarrow \hat{\theta} \xrightarrow{p} \theta$. Isso equivale dizer que a probabilidade do valor estimado diferir do parâmetro que se deseja estimar se aproxima de 0 conforme n aumenta.
- ❖ Por exemplo, a média amostral (\bar{Y}) é um estimador consistente da média populacional (μ_y).

$$\frac{1}{N} \sum_{i=1}^N y_i - \mu_y \xrightarrow{p} 0 \quad (4)$$
$$\frac{1}{N} \sum_{i=1}^N y_i \xrightarrow{p} \mu_y$$

Notas: ¹ Falta de viés não implica em consistência. ² Consistência não implica falta de viés.

Hands On

Serviço Militar Obrigatório

O exemplo de hoje é inspirado em *Angrist, Joshua D. 1990. "Lifetime Earnings and the Vietnam Era Draft Lottery: Evidence from Social Security Administrative Records". The American Economic Review 80 (3): 313–36.*

- ✚ Investiga o impacto do serviço militar sobre a renda futura dos indivíduos;
 - ✚ Havia debate a respeito de benefícios exagerados aos veteranos americanos...
 - ✚ ...mas comparações diretas sofriam com viés de endogeneidade

Contexto do alistamento militar no Brasil

- ❖ Há uma autoseleção no serviço militar obrigatório
 - ❖ Como existem menos vagas do que alistamentos, preferência é dada por quem deseja servir; e
 - ❖ Indivíduos com perspectiva de baixa remuneração na área civil, enxergam no alistamento uma grande oportunidade
- ❖ Por conta disso, uma comparação direta entre os que serviram no serviço militar obrigatório e os que não serviram, não permite inferência causal

Desejo de servir

- ❖ Soldo equivale a BRL 2.100 e serviço dura 1 ano, sem possibilidade de renovação.
- ❖ Salário civil (w_i^0) equivale a $\alpha_i + \epsilon_i^0$, sendo $\epsilon^0 \sim N(0, 800)$
- ❖ Existem 2 tipos de indivíduos: tipo A tem $\alpha_i = \alpha_a = 2.500$ e tipo B tem $\alpha_i = \alpha_b = 2.000$.
 - ❖ ambos indivíduos ocorrem com igual probabilidade
- ❖ Desejo de servir (D_i) depende da expectativa salarial ($E(w_{i0}^0)$), de tal forma que:

$$D_i = \begin{cases} 1 & \text{se } E(w_i^0) < 2.100 \\ 0 & \text{se c.c.} \end{cases}$$

Serviço militar

- ❖ Por restrições de vagas, apenas 50% dos que desejam servir conseguem ($P(S_i = 1|D_i = 1) = 0.5$)
 - ❖ escolha é aleatória
- ❖ δ_i mede o impacto do serviço militar sobre salário civil futuro (w_i^1), de tal forma que:

$$w_i^1 = \delta_i \alpha_i + \epsilon_i^1 \tag{5}$$
$$\delta_i = \begin{cases} 1.1 & \text{se } S_i = 1 \\ 1 & \text{se c.c.} \end{cases}$$

PGD

```
pgd <- function(N){  
  data <- data.frame("id"=paste0("cpf_", 1:N)) %>%  
    mutate(alpha = sample(c(2500, 2000),  
                          prob=c(0.5, 0.5),  
                          replace=TRUE,  
                          size=N),  
           epsilon_0=rnorm(N, 0, 800),  
           D = ifelse(alpha==2000, 1, 0),  
           w_0 = alpha + epsilon_0,  
           S = case_when(D==1 ~ rbern(N, 0.5),  
                          TRUE ~ 0),  
           delta = ifelse(S==1, 1.10, 1),  
           epsilon_1=rnorm(N, 0, 800),  
           w_1 = delta*alpha + epsilon_1  
    )  
}
```

O que sabemos?

➤ Dado o PGD, sabemos que:

$$E(w_i^1 | S = 0) = \frac{E(w_i^1 | S = 0 \cap \alpha_i = \alpha_a)P(\alpha_i = \alpha_a) + E(w_i^1 | S = 0 \cap \alpha_i = \alpha_b)P(\alpha_i = \alpha_b)}{P(S = 0 \cap \alpha_i = \alpha_b \cup S = 0 \cap \alpha_i = \alpha_a)} \quad (6)$$

$$E(w_i^1 | S = 0) = \frac{2500 \cdot 0.5 + 2000 \cdot 0.25}{0.75}$$

$$E(w_i^1 | S = 0) = 2333,33$$

$$E(w_i^1 | S = 1) = \frac{E(w_i^1 | S = 1 \cap \alpha_i = \alpha_a)P(\alpha_i = \alpha_a) + E(w_i^1 | S = 1 \cap \alpha_i = \alpha_b)P(\alpha_i = \alpha_b)}{P(S = 1 \cap \alpha_i = \alpha_b \cup S = 1 \cap \alpha_i = \alpha_a)} \quad (7)$$

$$E(w_i^1 | S = 1) = \frac{2200 \cdot 0.25}{0.25}$$

$$E(w_i^1 | S = 1) = 2200$$

Teste de média simples (militares)

- ❖ Quero testar se salário civil dos que serviram é igual a BRL 2.500,00 ($H_0 : \mu_{w^1} = 2500$)
- ❖ Sob H_0 , vale que:

$$\sqrt{n} \frac{\bar{\mu}_{w^1} - 2500}{\hat{\sigma}_{w^1}} \simeq N(0, 1)$$

- ❖ Consideraremos **5% como nível de significância**

Gerando amostra

```
set.seed(13)
data <- pgd(2000)
head(data)
```

##	id	alpha	epsilon_0	D	w_0	S	delta	epsilon_1	w_1
## 1	cpf_1	2500	-469.50076	0	2030.499	0	1.0	200.054589	2700.055
## 2	cpf_2	2000	892.29971	1	2892.300	1	1.1	-11.582969	2188.417
## 3	cpf_3	2000	999.73075	1	2999.731	1	1.1	-5.813859	2194.186
## 4	cpf_4	2000	-40.38681	1	1959.613	0	1.0	-221.801747	1778.198
## 5	cpf_5	2500	301.56497	0	2801.565	0	1.0	-112.126609	2387.873
## 6	cpf_6	2000	-972.90867	1	1027.091	0	1.0	548.351847	2548.352

Teste-t (comando em R)

```
data_serviu <- filter(data, S==1)
t.test(data_serviu$w_1, mu=2500, alternative="two.sided")

##
##  One Sample t-test
##
## data:  data_serviu$w_1
## t = -7.3809, df = 502, p-value = 6.571e-13
## alternative hypothesis: true mean is not equal to 2500
## 95 percent confidence interval:
##  2148.817 2296.474
## sample estimates:
## mean of x
##  2222.645
```

Teste-t (manualmente)

```
# Estimador amostral do desvio-padrão  
sd_serviu <- sd(data_serviu$w_1)  
se_hat <- sd_serviu/sqrt(nrow(data_serviu))  
se_hat
```

```
## [1] 37.57741
```

```
# Estimador amostral da média  
mu_hat <- mean(data_serviu$w_1)  
mu_hat
```

```
## [1] 2222.645
```

Teste-t (manualmente)

```
# estatística t
t <- (mu_hat - 2500)/se_hat
t

## [1] -7.380891

# IC (95%) para média amostral
ic <- c(mu_hat - 1.96*se_hat,
        mu_hat + 1.96*se_hat)
ic

## [1] 2148.994 2296.297
```

Erro tipo I: cálculo

Se usamos 5% como nível de significância, significa que em amostragens repetidas $\approx 5\%$ das vezes vamos rejeitar H_0 , mesmo sendo ela verdadeira. **Também podemos usar nosso PGD para conferir isso.**


```
gen_t_stat <- function(seed.i, mu.i, Si){  
  set.seed(seed.i)  
  data_temp <- pgd(1000) %>% filter(S==Si)  
  t.test(data_temp$w_1, mu=mu.i, alternative="two.sided")$statistic  
}  
teste <- sapply(1:1000, gen_t_stat, mu.i=2200, Si=1, simplify = TRUE)  
prob_erro_I <- sum(abs(teste)>=1.96)/length(teste)  
prob_erro_I
```

```
## [1] 0.044
```

Erro tipo I: visualização

```
fig <- ggplot() +  
  geom_density(aes(teste),  
               color=cores$verde_escuro,  
               fill=cores$verde_claro,  
               alpha=0.6,  
               adjust=1.5) +  
  geom_vline(xintercept = 1.96,  
             color=cores$vermelho_escuro, size=1.3, linetype=4) +  
  geom_vline(xintercept = -1.96,  
             color=cores$vermelho_escuro, size=1.3, linetype=4) +  
  labs(title="Distribuição da Estatística-t",  
        y="Densidade") +  
  tema_base_fundobranco()
```

Distribuição da Estatística-t



Teste de média simples (civis)

```
data_civil <- filter(data, S==0)
t.test(data_civil$w_1, mu=2500, alternative="two.sided")

##
## One Sample t-test
##
## data: data_civil$w_1
## t = -7.3743, df = 1496, p-value = 2.725e-13
## alternative hypothesis: true mean is not equal to 2500
## 95 percent confidence interval:
## 2296.127 2381.799
## sample estimates:
## mean of x
## 2338.963
```

* Importante notar que os intervalos de confiança dos salários de civis e militares (após o serviço militar) se cruzam.

Erro tipo II: cálculo

- Vamos testar se salário civil dos que não serviram é igual a BRL 2200 ($H_0 : \mu_{w_{S=0}} = 2200$)
 - Dado o PGD, sabemos que H_0 é falsa

```
data_civil <- filter(data, S==0)
t.test(data_civil$w_1, mu=2200, alternative="two.sided")

##
## One Sample t-test
##
## data: data_civil$w_1
## t = 6.3634, df = 1496, p-value = 2.617e-10
## alternative hypothesis: true mean is not equal to 2200
## 95 percent confidence interval:
## 2296.127 2381.799
## sample estimates:
## mean of x
## 2338.963
```


Erro tipo II: cálculo

Mantido 5% como nível de significância, nosso PGD indica que há uma probabilidade de $\approx 0,7\%$ de aceitarmos H_0 , mesmo sendo ela falsa.

```
teste <- sapply(1:1000, gen_t_stat, mu.i=2200, Si=0, simplify = TRUE)
prob_erro_II <- sum(abs(teste)<1.96)/length(teste)
prob_erro_II
```

```
## [1] 0.007
```

Erro tipo II: cálculo

Importante notar que o Erro Tipo II aumenta, conforme H_0 se aproxima da hipótese verdadeira.

```
teste <- sapply(1:1000, gen_t_stat, mu.i=2300, Si=0, simplify = TRUE)
prob_erro_II <- sum(abs(teste)<1.96)/length(teste)
prob_erro_II
```

```
## [1] 0.814
```

Teste de diferença de médias

- ✚ Vamos testar diretamente se salários dos civis é igual ao salário de militares após o serviço
($H_0 : \mu_{S=1} = \mu_{S=0} \equiv \mu_{S=1} - \mu_{S=0} = 0$)
- ✚ Sob H_0 , temos que:

$$\sqrt{n_{S=0} + n_{S=1}} \frac{\bar{\mu}_{w_{S=0}^1} - \bar{\mu}_{w_{S=1}^1} - 0}{\hat{\sigma}_{w_{S=0,S=1}^1}} \simeq N(0, 1)$$

Teste-t (comando em R)

```
t.test(data_serviu$w_1, data_civil$w_1,  
       alternative="two.sided", var.equal=TRUE)
```

```
##  
## Two Sample t-test  
##  
## data: data_serviu$w_1 and data_civil$w_1  
## t = -2.6729, df = 1998, p-value = 0.007581  
## alternative hypothesis: true difference in means is not equal to 0  
## 95 percent confidence interval:  
## -201.66150 -30.97386  
## sample estimates:  
## mean of x mean of y  
## 2222.645 2338.963
```

Teste-t (manualmente)

```
# Estimador amostral do desvio-padrão
```

```
sd_civil <- sd(data_civil$w_1)
```

```
n_civil <- nrow(data_civil)
```

```
sd_serviu <- sd(data_serviu$w_1)
```

```
n_serviu <- nrow(data_serviu)
```

```
sd_pool <- sqrt(((n_civil - 1) * sd_civil^2 + (n_serviu - 1) * sd_serviu^2) / (
```

```
se_hat <- sd_pool * sqrt(1/n_civil + 1/n_serviu)
```

```
se_hat
```

```
## [1] 43.51719
```

```
# Estimador amostral da média
```

```
mu_civil <- mean(data_civil$w_1)
```

```
mu_serviu <- mean(data_serviu$w_1)
```

```
mu_hat <- mu_serviu - mu_civil
```

```
mu_hat
```

```
## [1] -116.3177
```

Teste-t (manualmente)

```
# estatística t  
t <- (mu_hat - 0)/se_hat  
t
```

```
## [1] -2.672913
```

```
# IC (95%) para média amostral  
ic <- c(mu_hat - 1.96*se_hat,  
        mu_hat + 1.96*se_hat)  
ic
```

```
## [1] -201.61137 -31.02399
```

Interpretação dos resultados

- ❖ Pelo conjunto de evidências, fica claro que a expectativa salarial daqueles que serviram é menor do que daqueles que não serviram
 - ❖ e sabemos que isso é verdade pelo PGD
- ❖ Não podemos, a partir desse fato, concluir que serviço militar afeta negativamente a renda futura dos indivíduos
 - ❖ e sabemos, pelo PGD, que essa afirmação seria falsa
- ❖ Isso é um exemplo do que chamamos em econometria de **vies de seleção**
 - ❖ Indivíduos se autoselecionam para políticas públicas e uma mera comparação de beneficiários e não-beneficiários não permite conclusões causais.
 - ❖ Vamos ver mais sobre isso nas próximas aulas.

Efeito causal

- ❖ Pelo PGD, sabemos que o serviço militar aumenta a renda futura em BRL 200

$$\begin{aligned} E(w_i^1 | S = 0) - E(w_i^1 | S = 1) &= E(\delta_i \alpha_i + \epsilon_i^1) - E(\alpha_i + \epsilon_i^1) \\ &= E(\delta_i \alpha_i) + E(\epsilon_i^1) - E(\alpha_i) - E(\epsilon_i^1) \\ &= \delta_i E(\alpha_i) - E(\alpha_i) \\ &= (\delta_i - 1) E(\alpha_i) \\ &= 0.1 * 2000 \end{aligned} \tag{8}$$

- ❖ Há algum teste-t que me permita estimar esse efeito causal?

Efeito causal

```
data_rct_treated <- filter(data, D==1, S==1)
data_rct_control <- filter(data, D==1, S==0)
rct <- t.test(data_rct_treated$w_1, data_rct_control$w_1,
              alternative="two.sided", var.equal=TRUE)

rct
```

```
##
## Two Sample t-test
##
## data: data_rct_treated$w_1 and data_rct_control$w_1
## t = 4.1892, df = 1002, p-value = 3.046e-05
## alternative hypothesis: true difference in means is not equal to 0
## 95 percent confidence interval:
## 115.5801 319.2797
## sample estimates:
## mean of x mean of y
## 2222.645 2005.215
```

Efeito causal

- ❖ O efeito pontual estimado é de 217.43, com intervalo de confiança de 95% indo de 115.58 a 319.28.
 - ❖ Inclui o valor correto, portanto.
- ❖ Dentre os que desejam se alistar, o acesso ao serviço militar (tratamento) foi definido de maneira aleatória.
 - ❖ Com isso garantimos que o tratamento não depende de outros fatores que também explicam o salário;
 - ❖ Controla-se, assim, o viés de seleção
- ❖ Falaremos mais sobre a diferença entre efeito causal e correlação nas próximas aulas...

Lista II

Orientações gerais

- ❖ Objetivo: replicar um teste de diferença de médias e uma análise de erros tipo I e II, tal qual fizemos nessa aula.
 - ❖ mas usaremos um cenário alternativo
- ❖ Novamente, vocês vão partir de um arquivo *modelo*, que é um arquivo tipo Rmd.
 - ❖ Lembrem de renomear o arquivo para um nome com padrão “Lista_1_nome” antes de submeter;
 - ❖ submetam o relatório gerado (html) e o código (Rmd) antes da próxima aula, enviando-os para o email daniel.sgrimaldi@outlook.com.br;
 - ❖ o assunto do email deve seguir padrão “Lista_1_nome”

Cenário alternativo

- ✚ Dessa vez, imaginemos que o impacto do serviço militar acaba prejudicando a trajetória futura dos indivíduos, de tal forma que:

$$\delta_i = \begin{cases} 1.1 & \text{se } S_i = 1 \\ 1.3 & \text{se c.c.} \end{cases}$$

- ✚ Isso pode ocorrer, por exemplo, porque os que não entram para o serviço militar seguem estudando e os estudos têm impacto maior sobre a produtividade futura.

Lista II: especificações

- ❖ Vocês vão escrever a função `exec_lista_2`, que terá **obrigatoriamente 3 inputs**
 - ❖ `nome` (nome do aluno);
 - ❖ `sample_size=300` (tamanho da amostra a ser gerada para teste-t)
 - ❖ `n_samples=100` (qtd. de amostras a serem geradas para cálculo de erros tipo I e II)
- ❖ A função `exec_lista_2` terá **obrigatoriamente 2 outputs**
 - ❖ `nome`: um objeto tipo *character* com o nome do aluno;
 - ❖ `resultados`: um objeto tipo vetor com parâmetros de interesse

Lista II: especificações

- ❖ O teste-t
 - ❖ você deve testar se os civis e militares têm o mesmo salário (W_1)
- ❖ Erro Tipo I
 - ❖ calcule o Erro Tipo I em um teste-t a respeito do salário dos militares ($\mu_{W_{S=1}^1}$)
 - ❖ lembre-se que para esse teste, o valor de H_0 deve ser equivalente ao valor real de $\mu_{W_{S=1}^1}$, dado pelo PGD
- ❖ Erro Tipo II
 - ❖ calcule o Erro Tipo II em um teste-t a respeito do salário dos civis ($\mu_{W_{S=0}^1}$)
 - ❖ para esse cálculo considere como H_0 o valor de BRL 3.000,00

Implementa função

```
lista_2 <- exec_lista2("Daniel Grimaldi", sample_size = 100, n_samples=100)
```

Aluno

```
lista_2$nome
```

```
## [1] "Daniel Grimaldi"
```

Parâmetros estimados

```
lista_2$resultados
```

```
##      Erro_tipo_I Erro_tipo_II  estimativa      p-valor  estatistic-t  
## 2.000000e-02  9.400000e-01 -7.511055e+02  5.259254e-04 -3.585897e+00
```