

MÉTODOS QUANTITATIVOS I

AULA 5: MÍNIMOS QUADRADOS ORDINÁRIOS

Profs. Arthur Bragança e Daniel Grimaldi

MPAM-ENAP

16 de julho de 2025

INTRODUÇÃO

MODELO DE REGRESSÃO BIVARIADO

Modelo Populacional

Estimação

Interpretação

MODELO DE REGRESSÃO MULTIVARIADO

Modelo Populacional

Estimação

Regressão Residual

ECONOMETRIA (INTROD.)

- ▶ Na origem da maioria das análises de dados estão perguntas do tipo:
 - Como intervenção de política pública x influencia uma variável y ?
 - Que variáveis (x_1, x_2, \dots) determinam y ?
 - Etc.
- ▶ A econometria é o campo da economia que trata da estimação dessas **relações causais** nos dados.

ECONOMETRIA (INTROD.)

- ▶ O ponto de partida da econometria é a definição de um modelo populacional que descreve as relações entre as variáveis de interesse (“o que queremos explicar?”).
- ▶ Depois desenvolvem-se hipóteses para a estimação desses parâmetros utilizando uma amostra da população de interesse (**hipóteses de identificação**).
 - Hipóteses de identificação são essencialmente hipóteses sobre o processo gerador de dados.
 - Não é possível avaliá-las diretamente, i.e., não é possível **testá-las**.
 - Mas é **possível** (e **recomendável**) avaliar sua plausibilidade.
- ▶ Por último utiliza-se algum método de estimação (ex.: método dos momentos, máxima verossimilhança etc.) para estimar o modelo.

ECONOMETRIA (INTROD.)

- ▶ Nas próximas **três** aulas discutiremos o modelo de regressão linear.
- ▶ Esse é o modelo econométrico mais utilizado para realizarmos estudos empíricos.
- ▶ Discutiremos a estimação, a inferência e a interpretação desse modelo.
- ▶ Esse modelo tem inúmeras limitações. Entretanto,
 - Entender suas propriedades é fundamental para compreender modelos mais complexos.
 - Ele é o melhor modelo para examinar relações de **causa-e-efeito** em contextos específicos.
 - Ele pode ser útil mesmo quando ele não é o melhor modelo para examinar relações de **causa-e-efeito**.

MODELO DE REGRESSÃO BIVARIADO (1)

- ▶ Começaremos especificando um modelo de regressão linear simples.
- ▶ Esse modelo populacional tem apenas duas variáveis:
 - y : variável dependente (“o que queremos explicar”)
 - x : variável explicativa ou regressor (“o que explica y ”)
- ▶ Exemplos:
 - Efeito de mudanças no preço (x) na demanda por um produto (y);
 - Efeitos de escolaridade (x) sobre os salários dos indivíduos (y);
 - Efeitos do auxílio emergencial (x) sobre a pobreza das famílias (y).

MODELO DE REGRESSÃO BIVARIADO (2)

- ▶ No modelo de regressão linear a variável dependente (y) é uma função **aditiva** e **linear** da variável explicativa (x) e de um termo de erro não observável (u).
- ▶ Matematicamente, temos:

$$y_i = \alpha + \beta x_i + u_i$$

onde i indexa a i -ésima observação da população

MODELO DE REGRESSÃO BIVARIADO (3)

- ▶ O parâmetro de interesse do modelo de regressão linear é β .
- ▶ Esse parâmetro mede o efeito de uma mudança unitária em x_i sobre y_i .
- ▶ Note que

$$\frac{\Delta y_i}{\Delta x_i} = \beta, \forall x_i$$

Isso significa que o efeito de uma mudança unitária x_i sobre y_i é constante. **Hipótese muito restritiva!**

- ▶ Reinterpretação:
 - β é “média” dos efeitos de mudanças unitárias para diferentes níveis de x_i .

HIPÓTESES (1)

- ▶ Computar β requer hipóteses sobre relação entre regressor e termo de erro.
- ▶ Por quê?
 - Suponha que y_i é mais alto quando x_i é mais alto.
 - Isso implica que $\beta > 0$?
 - Sem hipóteses sobre a relação entre termo de erro e x_i é impossível determinar.
- ▶ Hipótese fundamental é que $E[u_i|x_i] = 0$.

HIPÓTESES (2)

► A hipótese fundamental é que $E[u_i|x_i] = 0$.

► **Implicação 1:** $E[u_i] = 0$

$$\textit{Prova: } E[u_i] = E[E[u_i|x_i]] = 0$$

► **Implicação 2:** $E[u_i x_i] = 0$

$$\textit{Prova: } E[u_i x_i] = E[E[u_i X_i|x_i]] = E[E[u_i|x_i]x_i] = 0$$

► Tipicamente supõe-se que $u_i \sim N(0, \sigma^2)$. Mas essa hipótese não é essencial.

O QUE $E[u_i|x_i] = 0$ SIGNIFICA?

- Considere um modelo conectando o logaritmo natural dos salários ($\log y_i$) com anos de estudo (e_i):

$$\log y_i = \beta_0 + \beta_1 e_i + u_i$$

- Considere que a habilidade dos indivíduos (a_i) é um determinante não observável dos salários:

$$u_i = a_i + \nu_i$$

- $E[u_i|e_i] = 0$ implica habilidade média dos indivíduos é idêntica independente da escolaridade. Por ex.,


$$E[a_i|e_i = 9] = E[a_i|e_i = 12] = E[a_i|x_i = 16] = 0$$

O QUE $E[u_i|x_i] = 0$ SIGNIFICA?

Note que $E[y_i|x_i] = \alpha + \beta x_i + E[u_i|x_i] = \alpha + \beta x_i$.

Figure 2.1

$E(y|x)$ as a linear function of x .



PARÂMETRO POPULACIONAL (1)

- Vimos que:

$$E[x_i|u_i] = 0 \implies E[u_i] = 0 \text{ e } E[x_i u_i] = 0$$

- O termo de erro pode ser escrito como:

$$u_i = y_i - \alpha - \beta x_i$$

- Isso implica que:

$$E[y_i - \alpha - \beta x_i] = 0$$

$$E[x_i(y_i - \alpha - \beta x_i)] = 0$$

- Podemos utilizar o sistema de equações acima para computar os parâmetros (α, β) .

PARÂMETRO POPULACIONAL (2)

- A primeira equação implica:

$$\alpha = E[y_i] - \beta E[x_i]$$

- A segunda equação implica:

$$E[x_i y_i] - \alpha E[x_i] - \beta E[x_i^2] = 0$$

- Substituindo α , temos:


$$E[x_i y_i] - E[x_i]E[y_i] - \beta (E[x_i^2] - E[x_i]^2) = 0$$

- Portanto:

$$\beta = \frac{E[x_i y_i] - E[x_i]E[y_i]}{E[x_i^2] - E[x_i]^2} = \frac{cov(x_i, y_i)}{var(x_i)}$$

ESTIMAÇÃO (1)

- Na prática iremos estimar os parâmetros a partir de uma amostra $\{(y_i, x_i) : i = 1, \dots, n\}$.



ESTIMAÇÃO (2)

- ▶ Na prática iremos estimar os parâmetros a partir de uma amostra $\{(y_i, x_i) : i = 1, \dots, n\}$.
- ▶ Note que cada observação i é uma retirada da população que segue a relação entre y_i e x_i do modelo populacional.
- ▶ Portanto, o modelo amostral é:

$$y_i = \alpha + \beta x_i + u_i, \forall i = \{1, \dots, n\}$$

- ▶ Como podemos estimar os parâmetros $(\hat{\alpha}, \hat{\beta})$?
- ▶ É possível estimar esses parâmetros utilizando os análogos amostrais das condições $E[u_i] = 0$ e $E[x_i u_i] = 0$.

ESTIMAÇÃO (3)

- Podemos utilizar os análogos amostrais das condições $E[u_i] = 0$ e $E[x_i u_i] = 0$.

$$\frac{1}{n} \sum_{i=1}^n (y_i - \alpha - \beta x_i) = 0$$

$$\frac{1}{n} \sum_{i=1}^n [x_i (y_i - \alpha - \beta x_i)] = 0$$

- Resolvendo o sistema:

$$\hat{\alpha} = \bar{y} - \hat{\beta} \bar{x}$$

$$\hat{\beta} = \frac{\sum (y_i - \bar{y})(x_i - \bar{x})}{\sum (x_i - \bar{x})^2} = \frac{\widehat{cov}(x_i, y_i)}{\widehat{var}(x_i)}$$

ESTIMAÇÃO (4)

- ▶ O estimador obtido é chamado de estimador de **método dos momentos**.
- ▶ Esse nome decorre dele ser construído a partir de condições de momento (“médias” que devem ser iguais a zero).
- ▶ Essas condições de momento decorrem diretamente das hipóteses do modelo de regressão linear, i.e., de hipóteses sobre o processo gerador de dados.
- ▶ Essas hipóteses que garantem que $\hat{\beta}$ identifica o **efeito causal** de mudanças de x sobre y .

RETA DE REGRESSÃO (1)

- A reta de regressão é a reta que conecta x com a expectativa condicional de y :

$$\hat{y}_i = \hat{\alpha} + \hat{\beta}x_i$$


- Os parâmetros $(\hat{\alpha}, \hat{\beta})$ podem ser interpretados como o intercepto e a inclinação dessa reta de regressão.
- Os resíduos podem ser definidos como a distância de cada observação para a reta de regressão:

$$\hat{u}_i = y_i - \hat{y}_i = y_i - \hat{\alpha} - \hat{\beta}x_i$$

RETA DE REGRESSÃO (2)

Figure 2.4

Fitted values and residuals.



MÍNIMOS QUADRADOS ORDINÁRIOS (1)

- ▶ A reta de regressão nos dá uma outra intuição para os parâmetros $(\hat{\alpha}, \hat{\beta})$.
- ▶ Esses parâmetros constroem a reta mais bem ajustada ao conjunto de dados.
- ▶ Formalmente,

$$\min_{\alpha, \beta} \sum_{i=1}^n u_i^2 = \min_{\alpha, \beta} \sum_{i=1}^n (y_i - \alpha - \beta x_i)^2$$

- ▶ Os parâmetros minimizam isso significa que esses parâmetros são aqueles que minimizam uma métrica de distância entre valores observados e preditos.

MÍNIMOS QUADRADOS ORDINÁRIOS (2)

- As condições de primeira ordem desse problema são:

$$\sum_{i=1}^n (y_i - \alpha - \beta x_i) = 0$$

$$\sum_{i=1}^n [x_i (y_i - \alpha - \beta x_i)] = 0$$

- O sistema de equações acima é exatamente o mesmo obtido utilizando método dos momentos.
- Solução é idêntica e resulta no mesmo intercepto e inclinação.

MODELO DE REGRESSÃO EM R

- ▶ Estimaremos um modelo de regressão no R em três etapas:
 1. Simular um conjunto de dados.
 2. Computar estimadores de mínimos quadrados ordinários manualmente.
 3. Computar estimadores de mínimos quadrados ordinários utilizando funções do R.
- ▶ Utilizaremos o RStudio.

PACOTES

Começamos carregando um pacote para estimar regressões lineares.

```
# Instala pacote #  
install.packages("estimatr")  
  
# Carrega pacote #  
library(estimatr)
```


COEFICIENTES DE MQO

Considere uma amostra de 10.000 observações de um conjunto de dados cujo modelo populacional é dado por $y_i = 5.5 * x_i + u_i$ em que $x_i \sim N(0, 1)$ e $u_i \sim N(0, 100)$.

```
## Constroi vetores y, x e u ##  
  
set.seed(33)  
  
x = rnorm(10000)  
  
u = 10*rnorm(10000)  
  
y = 5.5*x + u  
  
## Estima parâmetros ##  
  
beta = sum( (y- mean(y) )*(x - mean(x) ) ) / sum( (x-mean(x) )^2 )  
  
alpha = mean(y) - beta*mean(x)
```

COMANDO LM_ROBUST()

Podemos utilizar o comando `lm_robust()` para estimar regressões.

```
## Comando lm_robust() ##  
  
lm_robust(y ~ x)  
  
## Objeto com resultados...  
  
modelo = lm_robust(y ~ x)  
  
## O que temos no objeto?  
  
modelo$coefficients # coeficientes #  
modelo$vcov # matriz de variância #
```

FIT

- A variância de y pode ser decomposta em dois termos:

$$\begin{aligned} SQT &= \sum_{i=1}^n (y_i - \bar{y})^2 = \sum_{i=1}^n [(y_i - \hat{y}_i) + (\hat{y}_i - \bar{y})]^2 \\ &= \sum_{i=1}^n u_i^2 + 2 \sum_{i=1}^n u_i (\hat{y}_i - \bar{y}) + \sum_{i=1}^n (\hat{y}_i - \bar{y})^2 \\ &= \sum_{i=1}^n u_i^2 + \sum_{i=1}^n (\hat{y}_i - \bar{y})^2 \\ &= SQR + SQE \end{aligned}$$

- Importância relativa de SQR e SQE é medida de “ajuste” da regressão.


FIT

- ▶ Essa medida de ajuste é chamada de R^2 .
- ▶ Ela é definida como:

$$R^2 = \frac{SQE}{SQT} = 1 - \frac{SQR}{SQT}$$

- ▶ Intuitivamente ela nos dá uma medida de quanto da variância de y é explicado (no sentido estatístico) por x .

FIT



COMO EU FIZ ISSO?

```
# inicio o arquivo onde vou salvar o grafico
pdf("fit.pdf")

# faço gráfico dos dados utilizados na estimacao
plot(x,y, type = "p", xlab = "Indep. var.", ylab = "Dep. var.", lwd = 2, col = "chartreuse4")

# adiciono a linha com o y predito
abline(a = alpha, b = beta, lwd = 2, col = "black")

# fecho o arquivo
dev.off()
```


FIT

- ▶ O *fit* não tem relação com a identificação dos parâmetros do modelo.
- ▶ A identificação depende apenas da expectativa do erro condicional ao regressor ser zero ($E[u_i|x_i] = 0$).
- ▶ O R^2 se relaciona apenas com a proporção da variação em y que é explicada por x e que não é explicada por x (“explicada” por u).

β IDÊNTICO, R^2 DIFERENTE

```
# Modelo Original ##  
  
y = 5.5*x + u  
  
summary(lm_robust(y ~ x))  
  
Coefficients:  
      Estimate Std. Error t value Pr(>|t|) CI Lower CI Upper  DF  
(Intercept)  0.0474     0.1003   0.4725   0.6366 -0.1492   0.244 9998  
x            5.5604     0.1018  54.6002   0.0000   5.3608   5.760 9998  
  
Multiple R-squared:  0.2297 , Adjusted R-squared:  0.2296  
  
## Menos dispersão ##  
  
y = 5.5*x + 0.1*u  
  
summary(lm_robust(y ~ x))  
  
Coefficients:  
      Estimate Std. Error t value Pr(>|t|)  
(Intercept)  0.00474     0.01003   0.472   0.637  
x            5.50604     0.01018  540.664 <2e-16 ***  
---  
Multiple R-squared:  0.9669, Adjusted R-squared:  0.9669
```


MENOS DISPERSÃO



COMO EU FIZ ISSO?

```
# inicio o arquivo onde vou salvar o grafico
pdf("fit.pdf")

# faço gráfico dos dados utilizados na estimacao
plot(x,y, type = "p", xlab = "Indep. var.", ylab = "Dep. var.", lwd = 2, col = "deepskyblue2")

# adiciono a linha com o y predito
abline(a = alpha, b = beta, lwd = 2, col = "black")

# fecho o arquivo
dev.off()
```

INTERPRETAÇÃO DE COEFICIENTES

- Considere o modelo:

$$y_i = \alpha + \beta x_i + u_i$$

- Coeficiente β nos dá o efeito de um aumento unitário em x_i .
- Mas muitas vezes o interesse é em outras métricas.
- **Exemplos:**
 1. Um aumento unitário em x aumenta / diminui y em quantos %?
 2. Um aumento de 1% em x aumenta / diminui y em quantos %?
 3. Um aumento de um desvio-padrão de x aumenta / diminui y em quantos desvios-padrão?
- Duas alternativas: reescalonar coeficientes ou modificar modelo.

MODELO LOG-NÍVEL

- Considere o modelo:

$$\log y_i = \alpha + \beta x_i + u_i$$

- Esse modelo implica:

$$y_i = \exp(\alpha + \beta x_i + u_i)$$

- O efeito de um aumento unitário de x é:

$$\frac{\Delta y_i}{\Delta x_i} = \exp(\alpha + \beta(x_i + 1) + u_i) - \exp(\alpha + \beta x_i + u_i) = (\exp(\beta) - 1)y_i$$

MODELO LOG-NÍVEL

- ▶ Esse efeito como proporção de y (“percentual”) é:

$$\frac{\Delta y_i}{\Delta x_i} \times \frac{1}{y_i} = \exp(\beta) - 1 \approx \beta$$

- ▶ Portanto, o coeficiente desse modelo aproxima o efeito percentual de um aumento unitário de x .
- ▶ Aproximação funciona mal quando coeficiente é grande (**regra de bolso**: acima de 0.3).

MODELO LOG-LOG

- Considere o modelo:

$$\log y_i = \alpha + \beta \log x_i + u_i$$

- O coeficiente desse modelo identifica o efeito de um aumento de $\log x$ em $\log y$.
- Sabemos que uma pequena no logaritmo de uma variável aproxima uma mudança percentual nessa variável.
- Portanto, o modelo identifica efeitos percentuais em y de mudanças percentuais em x .
 - Em economia esse parâmetro é tipicamente chamado de elasticidade.

EXEMPLO: EDUCAÇÃO E SALÁRIOS

Iremos ilustrar questões relativas a forma funcional com dados reais.

```
root = ""  
  
setwd(root)  
  
# Instala e carrega pacote #  
  
install.packages("tidyverse")  
  
library(tidyverse)  
  
library(haven)  
  
# Abre banco de dados #  
  
twins = read_dta("pubtwins.dta")  
  
# Resume variáveis do banco de dados #  
  
summary(twins)
```

MODELO EM NÍVEL

Começando com uma regressão em nível.

```
mod = lm_robust(hrwage ~ educ, data = twins)

summary(mod)

Call:
lm_robust(formula = hrwage ~ educ, data = twins)

Standard error type: HC2

Coefficients:
      Estimate Std. Error t value Pr(>|t|) CI Lower CI Upper DF
(Intercept) -12.705      3.5909  -3.538 4.306e-04 -19.756  -5.654 678
educ          1.935      0.2757   7.017 5.495e-12   1.393   2.476 678

Multiple R-squared:  0.09498 , Adjusted R-squared:  0.09364
F-statistic: 49.24 on 1 and 678 DF, p-value: 5.495e-12
```


INTERPRETAÇÃO

- ▶ Um ano de estudo aumenta salário por hora em \$ 1.93.
- ▶ Qual o efeito percentual?

```
mod$coefficients["educ"]/mean(twins$hrwage)  
0.1340074
```

- ▶ Um ano de estudo aumenta salário por hora em cerca de 13%.

MODELO LOG-NÍVEL

Rodamos agora uma regressão log-nível.

```
mod = lm_robust(lwage ~ educ, data = twins)

summary(mod)
```

Call:
lm_robust(formula = lwage ~ educ, data = twins)

Standard error type: HC2

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	CI Lower	CI Upper	DF
(Intercept)	1.0077	0.15791	6.381	3.257e-10	0.69761	1.3177	678
educ	0.1022	0.01151	8.880	5.934e-18	0.07958	0.1248	678

Multiple R-squared: 0.1164 , Adjusted R-squared: 0.1151
F-statistic: 78.86 on 1 and 678 DF, p-value: < 2.2e-16

INTERPRETAÇÃO

- ▶ Um ano de estudo aumenta salário por hora em torno de 10%.
- ▶ Esse efeito é uma aproximação (efeito exato é $\exp(0.1022) - 1 = 0.1076$).
- ▶ Modelo em log diminui influência dos *outliers* no resultado (mais sobre isso nas próximas aulas)

MODELO DE REGRESSÃO MULTIVARIADO

- Considere agora a relação populacional entre uma variável dependente (y) e um conjunto de regressores (x_1, \dots, x_k) é:

$$y_i = \beta_1 x_{1i} + \beta_2 x_{2i} + \dots + \beta_k x_{ki} + u_i = X_i' \beta + u_i, \forall i$$

onde i indexa a i -ésima observação da população

X_i é um vetor $k \times 1$ de regressores e β é um vetor $k \times 1$ de parâmetros.

Normalmente a primeira linha de X é uma constante.

HIPÓTESES (REVISÃO)

- A hipótese fundamental é que $E[u_i|X_i] = 0$.

- **Implicação 1:** $E[u_i] = 0$

$$\textit{Prova: } E[u_i] = E[E[u_i|X_i]] = 0$$

- **Implicação 2:** $E[u_i X_i] = 0$

$$\textit{Prova: } E[u_i X_i] = E[E[u_i X_i|X_i]] = E[E[u_i|X_i]X_i] = 0$$

- Tipicamente supõe-se que $u_i \sim N(0, \sigma^2)$. Mas essa hipótese não é essencial.

INTERPRETAÇÃO (1)

- ▶ β_k é efeito de uma mudança em x_k sobre y mantendo os outros regressores fixos
- ▶ Isso significa que modelo permite estudar efeito de mudar apenas um regressor mesmo quando dados incluem variação de todos eles ao mesmo tempo.
- ▶ Tenta “emular” experimento controlado em que só um regressor é manipulado.

INTERPRETAÇÃO (2)

- ▶ Temos interesse no efeito de múltiplos regressores em y .
- ▶ **Modelo de preços hedônicos:**
 - p_i é o preço de um bem heterogêneo (ex.: carro)
 - X_i é vetor de características observáveis desse bem (ex.: marca, potência, cor, tamanho etc.)
 - Interesse em estimar o efeito de diferentes características sobre preço (“valoração”).
- ▶ Modelo de regressão multivariado conectando preço a diferentes características:

$$p_i = X_i' \beta + u_i$$

INTERPRETAÇÃO (3)

- ▶ Temos interesse no efeito de um regressor x_{i1} sobre y .
- ▶ Mas inserimos regressores adicionais para garantir que regressor não é correlacionado com termo de erro (“controles”).
- ▶ Considere o modelo:

$$y_i = \beta_0 + \beta_1 x_{i1} + \varepsilon_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + u_i$$

- ▶ x_{i1} correlacionado com termo de erro da primeira equação ($E[x_{i1}\varepsilon_i] \neq 0$).
- ▶ x_{i1} não correlacionado com termo de erro da primeira equação ($E[x_{i1}u_i] = 0$).

PARÂMETRO POPULACIONAL (1)

- Podemos utilizar $E[X_i u_i] = 0$ para derivar o parâmetro populacional.
- Note que $u_i = y_i - X_i' \beta$. Portanto,

$$E[X_i u_i] = E[X_i (y_i - X_i' \beta)] = E[X_i y_i] - E[X_i X_i'] \beta = 0$$

- Isso implica que o parâmetro populacional é:

$$\beta = E[X_i X_i']^{-1} E[X_i y_i]$$

- Lembre que X_i é $k \times 1$ o que implica que $E[X_i X_i']^{-1}$ tem dimensão $k \times k$ e $E[X_i y_i]$ dimensão $k \times 1$.
- Logo, β tem dimensão $k \times 1$ como gostaríamos.

PARÂMETRO POPULACIONAL (2)

- Note que $E[u_i|X_i] = 0$ implica:

$$E[y_i|X_i] = X_i\beta$$

- Isso implica que (y_i, X_i) tem distribuição normal bivariada se $u_i \sim N(0, \sigma^2)$.
- Em estatística aprendemos que sob normalidade conjunta β é dado por $E[X_i X_i']^{-1} E[X_i y_i]$.

ESTIMAÇÃO (1)

- Suponha que queremos estimar os parâmetros do modelo de regressão linear a partir de uma amostra $\{(y_i, x_{i1}, \dots, x_{ik}) : i = 1, \dots, n\}$.
- Note que cada observação i é uma retirada da população que segue a relação entre y_i e X_i do modelo populacional.
- Logo, o modelo amostral pode ser escrito como:

$$y = X\beta + u,$$

$$\text{onde } X = \begin{bmatrix} X'_1 \\ \vdots \\ X'_n \end{bmatrix} = \begin{bmatrix} x_{11} & \cdots & x_{1k} \\ \vdots & \ddots & \vdots \\ x_{n1} & \cdots & x_{nk} \end{bmatrix}; Y = \begin{bmatrix} y_1 \\ \vdots \\ y_n \end{bmatrix}; u = \begin{bmatrix} u_1 \\ \vdots \\ u_n \end{bmatrix}$$

ESTIMAÇÃO (2)

- Estimador de mínimos quadrados ordinários (MQO) é o conjunto de β s que minimiza a soma do quadrado dos resíduos:

$$\hat{\beta} = \underset{\beta}{\operatorname{argmin}} \sum_{i=1}^n u_i^2 = \underset{\beta}{\operatorname{argmin}} \sum_{i=1}^n (y_i - X_i' \beta)^2$$

- Condição de primeira ordem (use regra da cadeia):

$$\sum_{i=1}^n 2X_i(y_i - X_i' \hat{\beta}) = 0$$

$$\sum_{i=1}^n (X_i y_i) - \sum_{i=1}^n (X_i X_i') \hat{\beta} = 0$$

$$\hat{\beta} = \left(\sum_{i=1}^n X_i X_i' \right)^{-1} \left(\sum_{i=1}^n X_i y_i \right)$$

ESTIMAÇÃO (3)

- Em notação matricial:

$$\sum_{i=1}^n u_i^2 = u'u = (Y - X\beta)'(Y - X\beta)$$

- Minimizando $u'u$:

$$-2X'Y + 2X'X\hat{\beta} = 0 \implies \hat{\beta} = (X'X)^{-1}(X'Y)$$

- Note que o estimador só existe se a matriz X tem o posto cheio (i.e., é inversível).

ESTIMAÇÃO (3)

- Estimador equivalente é obtido se tentamos tornar condição $E[X_i u_i] = 0$ na amostra o mais próxima possível de zero (método dos momentos).

$$\frac{1}{n} \sum_{i=1}^n X_i (y_i - X_i' \hat{\beta}) = 0$$

$$\hat{\beta} = \left(\sum_{i=1}^n X_i X_i' \right)^{-1} \left(\sum_{i=1}^n X_i y_i \right)$$

- Estimador equivalente é obtido se maximizamos a chance de $u_i = y_i - X_i' \beta$ ser normal com média 0 e variância σ^2 (máxima verossimilhança)

EXEMPLO: DADOS DE EDUCAÇÃO E SALÁRIOS

Começando com uma regressão bivariada.

```
# Regressões #

modelo1 = lm_robust(lwage ~ educ, data = twins) # resultados armazenados em uma lista contendo diferentes
objetos como: #

# coeficientes #

modelo1$coefficients

# matriz de variância #

modelo1$vcov

# ... #
```

Podemos adicionar controles.

```
modelo2 = lm_robust(lwage ~ educ + age + age2, data = twins) # é possível adicionar controles #

summary(modelo2)

modelo3 = lm_robust(lwage ~ educ + age + age2 + female + white, data = twins) # é possível adicionar controles
#

summary(modelo3)
```

COMANDO MODELSUMMARY()

É possível exportar os resultados da regressão para tabelas de diferentes formatos.

```
# instala e carrega pacote #  
  
install.packages("modelsummary")  
  
library(modelsummary)  
  
# podemos exportar resultados para tabela em formatos como "texto", "html" ou "latex" #  
  
modelos = list("MQO 1" = modelo1,  
              "MQO 2" = modelo2,  
              "MQO 3" = modelo3)  
  
modelsummary(modelos)  
  
# pode salvar como Markdown, Latex ou mesmo Word (instalar pacote "flextable")
```


INTERPRETAÇÃO (1)

- ▶ Que controles queremos incluir?
- ▶ **Bons controles:**
 - “Explicam” variável dependente (**regra de bolso:** sua inclusão aumenta o R^2);
 - Potencialmente correlacionados com regressor de interesse (mas não determinados por ele).
- ▶ **Controles ruins:**
 - ▶ Não explicam variável dependente ou são muito correlacionados entre si;
 - ▶ São “endógenos” (potencialmente determinados pelo regressor de interesse).

INTERPRETAÇÃO (2)

- **Exemplo:** Considere o uma regressão conectando salários com educação:

$$\log y_i = \alpha + \beta e_i + W_i' \Gamma + u_i$$

- Que controles incluir em X_i ?
 - Controles como idade, sexo, cor, estado civil, habilidade, onde reside etc. são bons controles
 - Características do emprego são controles ruins (ex.: setor de atividade).

O QUE OS CONTROLES FAZEM? (1)

- ▶ Controlar por uma variável é equivalente a limpar a variação das variáveis de interesse que vem dos controles.
- ▶ É possível ver isso com a ideia de **regressão residual**.
- ▶ Considere modelo de regressão:

$$y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + u_i$$

- ▶ É possível expressar β_1 e β_2 como:

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n \hat{r}_{i1} y_i}{\sum_{i=1}^n \hat{r}_{i1}^2}$$

$$\hat{\beta}_2 = \frac{\sum_{i=1}^n \hat{r}_{i2} y_i}{\sum_{i=1}^n \hat{r}_{i2}^2}$$

O QUE OS CONTROLES FAZEM? (2)

- ▶ r_{i1} e r_{i2} são resíduos de regressões de x_{1i} em x_{2i} e x_{2i} em x_{1i} , respectivamente.
- ▶ Intuição é que “controlar” limpa a variação de x_1 ou x_2 que vem do outro fator.
- ▶ Isso permite estimar efeitos de uma variável mantendo a outra fixa.

EXEMPLO

- Relação entre y e os regressores x_1 e x_2 seja descrita pelo modelo populacional:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + u$$

- Relação entre x_1 e x_2 é descrita por:

$$x_2 = \alpha x_1 + \nu$$

- Suponha que os parâmetros populacionais sejam $\beta_0 = 0.1$, $\beta_1 = 0.6$, $\beta_2 = 0.4$ e $\alpha = 0.5$ e as distribuições $u \sim N(0, 4)$, $\nu \sim N(0, 16)$ e $x_1 \sim N(0, 1)$.

DADOS

Simulo 10.000 observações dos vetores u , ν , x_1 , x_2 e y .

```
# Vetores #  
  
set.seed(1985)  
  
beta0 = 0.1  
beta1 = 0.6  
beta2 = 0.4  
alpha = 0.5  
  
u = rnorm(10000, mean = 0, sd = 2)  
v = rnorm(10000, mean = 0, sd = 4)  
x1 = rnorm(10000, mean = 0, sd = 1)  
x2 = alpha*x1+v  
  
y = beta0 + beta1*x1 + beta2*x2 + u  
  
dados = data.frame(cbind(y,x1,x2))
```

REGRESSÃO MULTIVARIADA

Rodo regressão longa.

```
# Regressão #  
  
full.model = lm_robust(y ~ x1 + x2, data = dados)  
  
summary(full.model)
```

Standard error type: HC1

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	CI Lower	CI Upper	DF
(Intercept)	0.06576	0.019964	3.294	9.915e-04	0.02663	0.1049	9997
x1	0.61181	0.020065	30.491	2.504e-195	0.57248	0.6511	9997
x2	0.39489	0.005066	77.950	0.000e+00	0.38496	0.4048	9997

Multiple R-squared: 0.4366 , Adjusted R-squared: 0.4364

F-statistic: 3858 on 2 and 9997 DF, p-value: < 2.2e-16

REGRESSÃO RESIDUAL

Rodo regressões entre os regressores.

```
res.reg1 = lm_robust(x1 ~ x2, data = dados)
res.reg2 = lm_robust(x2 ~ x1, data = dados)
dados$r1 = dados$x1 - res.reg1$fitted.values
dados$r2 = dados$x2 - res.reg2$fitted.values
```


REGRESSÃO RESIDUAL

Rodo regressões residuais.

```
summary(lm_robust(y ~ r1, data = dados))
```

Call:

```
lm_robust(formula = y ~ r1, data = dados)
```

Standard error type: HC2

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	CI Lower	CI Upper	DF
(Intercept)	0.04987	0.02590	1.926	5.415e-02	-0.0008902	0.1006	9998
r1	0.61181	0.02636	23.210	4.098e-116	0.5601380	0.6635	9998

Multiple R-squared: 0.05184 , Adjusted R-squared: 0.05175

F-statistic: 538.7 on 1 and 9998 DF, p-value: < 2.2e-16

REGRESSÃO RESIDUAL

Rodo regressões residuais.

```
summary(lm_robust(y ~ r2, data = dados))
```

Call:

```
lm_robust(formula = y ~ r2, data = dados)
```

Standard error type: HC2

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	CI Lower	CI Upper	DF
(Intercept)	0.04987	0.021497	2.32	0.02037	0.007732	0.09201	9998
r2	0.39489	0.005439	72.60	0.00000	0.384224	0.40555	9998

Multiple R-squared: 0.3466 , Adjusted R-squared: 0.3465

F-statistic: 5271 on 1 and 9998 DF, p-value: < 2.2e-16