

# MÉTODOS QUANTITATIVOS I

## AULA 6: MÍNIMOS QUADRADOS ORDINÁRIOS

Profs. Arthur Bragança e Daniel Grimaldi

MPAM-ENAP

6 de agosto de 2025

INTRODUÇÃO

PROPRIEDADES

INFERÊNCIA EM MQO

HETEROCEDASTICIDADE

MQO EM GRANDES AMOSTRAS

PROBLEMAS COM MQO

# INTRODUÇÃO

- ▶ Na aula passada estudamos os modelo de regressão bivariado e multivariado.
- ▶ Nessa aula:
  - Estudaremos as propriedades dos estimadores de MQO.
  - Estudaremos como testar hipóteses sobre os parâmetros de MQO.
  - Discutiremos o que ocorre quando variância do termo de erro não é constante.
  - Estudaremos as propriedades dos estimadores de MQO em amostras grandes.
  - Discutiremos o que ocorre quando há correlação entre regressores e termo de erro.

# PROPRIEDADES (1)

- ▶ **Mínimos Quadrados Ordinários (MQO)**: estimadores com propriedades desejáveis.
- ▶ O que são propriedades desejáveis?
  1. **Não viesado**: expectativa do estimador do parâmetro é igual ao parâmetro verdadeiro
  2. **Eficiente**: variância do estimador é a menor possível
- ▶ Para ver essas propriedades iremos listar um conjunto de hipóteses.
- ▶ Depois derivaremos a média e a variância do estimador.

# PROPRIEDADES

## ► Hipóteses:

1. **Modelo populacional:** o modelo populacional é

$$y = X\beta;$$

2. **Amostragem aleatória:**  $\{(y_i, x_{i1}, \dots, x_{ik}) : i = 1, \dots, n\}$  é uma amostra independente e identicamente distribuída;
3. **Independência condicional:**  $E[u|X] = 0$ ;
4. **Variação em  $X$ :**  $X = [X'_1, \dots, X'_n]'$  é matriz  $n \times k$  com posto cheio;
5. **Homocedasticidade:** a variância o termo de erro é constante:

$$V[u|X] = E[uu'|X] = \sigma^2 I$$

- As hipóteses acima muitas vezes são chamadas de hipóteses de Gauss-Markov.

■ Muitas vezes é adicionada a hipótese que  $u|X \sim N(0, \sigma^2 I)$ .

## MÉDIA DE $\hat{\beta}$

- A média do estimador de MQO condicional a  $X$  é

$$\begin{aligned} E[\hat{\beta}|X] &= E[(X'X)^{-1}X'y|X] \\ &= E[(X'X)^{-1}X'(X\beta + u)|X] \\ &= \beta + (X'X)^{-1}X'E[u|X] \\ &= \beta \end{aligned}$$

- Lembre que  $E[\hat{\beta}] = E[E[\hat{\beta}|X]]$ .
- Isso significa  $E[\hat{\beta}] = E[E[\hat{\beta}|X]] = E[\beta] = \beta$ .
- Logo,  $\hat{\beta}$  é um estimador não viesado de  $\beta$ .

## MÉDIA DE $\hat{\beta}$ (BIVARIADO)

- A média do estimador de MQO condicional a  $x_i$  é

$$\begin{aligned} E[\hat{\beta}|x_i] &= E \left[ \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2} | x_i \right] \\ &= E \left[ \frac{\sum (x_i - \bar{x})y_i}{\sum (x_i - \bar{x})^2} | x_i \right] - E \left[ \frac{\sum (x_i - \bar{x})\bar{y}}{\sum (x_i - \bar{x})^2} | x_i \right] \\ &= E \left[ \frac{\sum (x_i - \bar{x})(\alpha + \beta x_i + u_i)}{\sum (x_i - \bar{x})^2} | x_i \right] \\ &= \beta + E \left[ \frac{\sum (x_i - \bar{x})u_i}{\sum (x_i - \bar{x})^2} | x_i \right] \\ &= \beta + \left[ \frac{\sum (x_i - \bar{x})}{\sum (x_i - \bar{x})^2} \right] E[u_i | x_i] = \beta \end{aligned}$$

- Isso significa  $E[\hat{\beta}] = E[E[\hat{\beta}|x_i]] = E[\beta] = \beta$ .

## VARIÂNCIA DE $\hat{\beta}$

- A variância de  $\hat{\beta}$  condicional a  $X$  é:

$$V[\hat{\beta}|X] = E \left[ (\hat{\beta} - \beta)(\hat{\beta} - \beta)' | X \right]$$

- Note que:

$$\begin{aligned}\hat{\beta} &= (X'X)^{-1}X'y = (X'X)^{-1}(X'X)\beta + (X'X)^{-1}X'u \\ \implies \hat{\beta} - \beta &= (X'X)^{-1}X'u\end{aligned}$$

- Portanto:

$$\begin{aligned}V[\hat{\beta}|X] &= E \left[ ((X'X)^{-1}X'u)((X'X)^{-1}X'u)' | X \right] \\ &= E \left[ (X'X)^{-1}X'uu'X(X'X)^{-1} | X \right] \\ &= (X'X)^{-1}X'E[uu'|X]X(X'X)^{-1} \\ &= \sigma^2(X'X)^{-1}\end{aligned}$$



## VARIÂNCIA DE $\hat{\beta}$

- A lei da variância total diz:

$$V[\hat{\beta}] = E \left[ V[\hat{\beta}|X] \right] + V \left[ E[\hat{\beta}|X] \right]$$

- Temos:

$$V \left[ E[\hat{\beta}|X] \right] = V[\beta] = 0$$

- Logo,

$$V[\hat{\beta}] = E \left[ V[\hat{\beta}|X] \right] = \sigma^2(X'X)^{-1}$$

- Variância do estimador de MQO depende da variância do termo de erro (“variância residual de  $y$ ”) e da variância dos regressores.

## VARIÂNCIA DE $\hat{\beta}$ (BIVARIADO)

- A variância de  $\hat{\beta}$  condicional a  $x_i$  é:

$$V[\hat{\beta}|x_i] = E[(\hat{\beta} - \beta)^2|x_i]$$

- Note que:

$$\begin{aligned}\hat{\beta} &= \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2} = \beta + \frac{\sum_{i=1}^n (x_i - \bar{x})u_i}{\sum_{i=1}^n (x_i - \bar{x})^2} \\ \Rightarrow \hat{\beta} - \beta &= \frac{\sum_{i=1}^n (x_i - \bar{x})u_i}{\sum_{i=1}^n (x_i - \bar{x})^2} = \sum_{i=1}^n w_i u_i\end{aligned}$$

- Portanto:

$$\begin{aligned}V[\hat{\beta}|x_i] &= E\left[\left(\sum_{i=1}^n w_i u_i\right)^2 | x_i\right] = E\left[\left(\sum_{i=1}^n w_i^2 u_i^2\right) | x_i\right] \\ &= \sigma^2 \left(\sum_{i=1}^n w_i\right)^2 = \frac{\sigma^2}{\sum_{i=1}^n (x_i - \bar{x})^2}\end{aligned}$$

# TEOREMA DE GAUSS-MARKOV

- ▶ Se as hipóteses 1-5 são válidas, o estimador de MQO é o melhor estimador linear não viesado do vetor  $\beta$ .
- ▶ O que isso significa? Considere a classe de estimadores lineares:

$$\tilde{\beta} = \sum_{i=1}^n W_i y_i,$$

em que  $W_i$  é uma função da amostra.

- ▶ Teorema de Gauss-Markov diz que  $W_i = (X_i X_i')^{-1} X_i$  é a função que:
  1. ... faz com que  $\tilde{\beta}$  tenha a menor variância possível (“melhor”)
  2. ... entre os estimadores que  $E[\tilde{\beta}] = \beta$  (“não viesado”)

# DISTRIBUIÇÃO NORMAL

- ▶ **Hipótese adicional:**

$$u|X \sim N(0, \sigma^2 I)$$

- ▶ Essa hipótese adicional caracteriza o que chamamos de **modelo de regressão linear clássico**.
- ▶ Ela implica que o estimador  $\hat{\beta}$  tem distribuição normal.
- ▶ **Por quê?**

$$\hat{\beta} = \beta + (X'X)^{-1}X'u$$

$$u|X \sim N(0, \sigma^2 I) \implies \hat{\beta} \sim N(\beta, \sigma^2(X'X)^{-1})$$

# INFERÊNCIA ESTATÍSTICA (1)

- ▶ Considere o modelo populacional:

$$y = X\beta + u$$

- ▶ Como testar hipóteses sobre  $\hat{\beta}$ ?
- ▶ Vimos que  $(\hat{\beta} - \beta)/\text{sd}(\hat{\beta}) \sim N(0, 1)$ .
- ▶ Isso permite construir intervalos de confiança e testar hipóteses.
  - ... se conhecermos  $\sigma^2$ ...
  - ... mas na prática precisamos estimar  $\sigma^2$
- ▶ O que fazer?

## INFERÊNCIA ESTATÍSTICA (2)

- ▶ Seja  $\text{ep}(\hat{\beta}) = \hat{\sigma}^2(X'X)^{-1}$  o erro-padrão dos estimadores de MQO.
- ▶ Temos que

$$(\hat{\beta} - \beta) / \text{ep}(\hat{\beta}) \sim t_{n-k-1}$$

em que  $t_{n-k-1}$  é a distribuição t-Student com  $n - k - 1$  graus de liberdade.

- ▶ Essa distribuição pode ser utilizada para testar hipóteses.
  - Essa distribuição converge para uma normal padronizada quando número de graus de liberdade tende a infinito (ex.:  $> 120$ ).

# INFERÊNCIA ESTATÍSTICA (3)

- Estimamos a variância dos erros com seguinte formula:

$$\begin{aligned}\widehat{\sigma^2} &= \frac{1}{n-k-1} \sum_{i=1}^n \widehat{u}_i^2 \\ &= \frac{1}{n-k-1} \sum_{i=1}^n \left( y_i - X_i' \widehat{\beta} \right)^2 \\ &= \frac{1}{n-k-1} (y - X\beta)(y - X\beta)'\end{aligned}$$

- Usar  $n - k - 1$ ,  $n - k$  ou  $n$  não faz diferença em grandes amostras.
  - Diferentes pacotes / opções no R utilizam diferentes denominadores.

# TESTE DE HIPÓTESES (1)

- Começamos considerando um teste cuja hipótese nula é

$$H_0 : \beta_k = 0$$

- Calculamos estatística  $t_k = \beta_k / \text{ep}(\beta_k)$
- Sob a hipótese nula,  $t_k \sim N(0, 1)$  (em amostras grandes)
- **Regra de decisão:** rejeitamos  $H_0$  quando  $t_k$  é tal que é improvável que hipótese nula seja verdadeira.
  - $H_1 : \beta_k > 0$ :  $H_0$  é rejeitada se  $t_k$  é positivo e “grande”
  - $H_1 : \beta_k < 0$ :  $H_0$  é rejeitada se  $t_k$  é negativo e “grande”
  - $H_1 : \beta_k \neq 0$ :  $H_0$  é rejeitada se  $|t_k|$  é “grande”




## TESTE DE HIPÓTESES (2)

- ▶ O que define ser “grande” é nível de significância adotado.
- ▶ **Nível de significância:** probabilidade de rejeitar hipótese nula que é verdadeira
- ▶ **Níveis típicos:** 10%, 5% e 1% (5% é o mais comum)
- ▶ **p-valor:** qual o menor nível de significância para o qual eu não rejeitaria a hipótese nula?
  - Inverte o cálculo.


# TESTE DE HIPÓTESES (3)

5% rejection rule for the alternative  $H_1: \beta_j > 0$  with 28 *df*.




# TESTE DE HIPÓTESES (4)

5% rejection rule for the alternative  $H_1: \beta_j < 0$  with 18 *df*.



# TESTE DE HIPÓTESES (5)

5% rejection rule for the alternative  $H_1: \beta_j \neq 0$  with 25 *df*.



# HIPÓTESES MÚLTIPLAS (1)

- ▶ Muitas vezes estamos interessados em fazer testes sobre mais de um coeficiente.
  - Coeficientes conjuntamente iguais a zero?
  - Soma de coeficientes é igual a um determinado valor?
  - Etc.
  
- ▶ **Ideia:**
  - Constrói hipótese nula.
  - Roda modelo impondo que hipótese nula é verdadeira (modelo restrito)
  - Roda modelo sem impor que hipótese nula é verdadeira (modelo irrestrito)
  - Compara os modelos (como?).

## HIPÓTESES MÚLTIPLAS (2)

- Como comparar os modelos?
- Podemos utilizar o  $R^2$  para construir estatística de teste.

$$F = \frac{(R^2_{ur} - R^2_r)/q}{(1 - R^2_{ur})/(n - k - 1)}$$

em que  $ur$  denota o modelo irrestrito,  $r$  o modelo restrito e  $q$  é o número de restrições sendo testadas

- A estatística  $F$  tem distribuição F-Snedecor com  $q$  graus de liberdade no numerador e  $n - k - 1$  no denominador.
- Logo, podemos utilizar essa distribuição para testar hipóteses múltiplas.

# HIPÓTESES MÚLTIPLAS (3)

- Considere o modelo:

$$\log w_i = \beta_0 + \beta_1 \text{educ}_i + \beta_2 \text{age}_i + \beta_3 \text{age}_i^2 + u_i$$

- Suponha que queremos testar  $H_0 : \beta_2 = \beta_3 = 0$ .
- Rodamos modelo restrito:

$$\log w_i = \beta_0 + \beta_1 \text{educ}_i + u_i$$

e computamos  $R^2_r$ .

- Depois rodamos modelo completo e computamos  $R^2_{ur}$ .
- Usamos os coeficientes de ajustes para construir estatística  $F$  (note que  $k = 4$  e  $q = 2$ ).

# HIPÓTESES MÚLTIPLAS (4)

- Comando **linearHypothesis()** permite testar hipóteses múltiplas.

```
# Instala e carrega pacote #  
  
install.packages("car")  
  
library(car)  
  
# Testando significancia conjunta #  
  
modelo = lm_robust(lwage ~ educ + age + age2 + female + white, data = twins, se_type = "classical") # modelo  
que queremos analisar #  
  
hipotese.nula <- c("age=0", "age2=0") # hipotese conjunta a ser testada #  
  
linearHypothesis(modelo, hipotese.nula, test = "F") # teste F #
```



# HETEROCEDASTICIDADE (1)

Problema! Variância do erro não é constante.

```
# Estimo modelo lm_robust() #  
  
modelo = lm_robust(lwage ~ educ + age + age2 + female + white, data = twins, se_type = "classical")  
  
# Computo erros #  
  
twins$erro = modelo$residuals  
  
# regressor x erros (ou var. dep.)  
  
plot(twins$educ, twins$erro)  
plot(twins$educ, twins$lwage)  
plot(twins$age, twins$erro)  
plot(twins$age, twins$lwage)
```

Erros padrão robustos a heterocedasticidade dados por:

$$V(\hat{\beta}) = (X'X)^{-1}X'E[\hat{u}\hat{u}'|X]X(X'X)^{-1}$$

## HETEROCEDASTICIDADE (2)

Pacote **lm\_robust** estima automaticamente erros-padrão robustos a heterocedasticidade.

```
# Estimo modelo com erro-padrão robusto #  
  
modelo = lm_robust(lwage ~ educ + age + age2 + female + white, data = twins, se_type = "HC1")  
  
# Opção type = "" do comando controla formula utilizada "
```

Diferentes opções do comando denotam diferentes ajustes de graus de liberdade na estimação da matriz de variância  $E[\hat{u}\hat{u}'|X]$ .

**Problema!** Mínimos quadrados ordinários deixa de ser eficiente.

# HETEROCEDASTICIDADE (3)

- ▶ Mínimos Quadrados Generalizados: opção eficiente.
- ▶ Considere que

$$V[u|X] = \sigma^2 h(X)$$

- ▶ Note que

$$V \left[ u / \sqrt{h(X)} | X \right] = \sigma^2$$

- ▶ Estimador eficiente obtido regredindo  $y/h(X)$  em  $x/h(X)$ .
- ▶ **Dois casos:**
  - $h(X)$  é conhecido: estimação direta
  - $h(X)$  não é conhecido: roda MQO, computa  $\hat{h}(X)$  e estima novamente.

# MQO EM GRANDES AMOSTRAS

- Considere o modelo:

$$y = X\beta + u$$

- Derivamos as propriedades de  $\hat{\beta}$  em amostras finitas.
- Mas, mais e mais, obtemos  $\hat{\beta}$  em amostras cada vez maiores.
- Quais as propriedades dos estimadores de MQO quando o número de observações cresce arbitrariamente ( $n \rightarrow \infty$ )?

# CONSISTÊNCIA (1)

- $\hat{\beta}$  é um estimador consistente de  $\beta$ .

$$\text{plim}(\hat{\beta}) = \beta$$

- **Intuição:** à medida que amostra cresce o vetor de parâmetros estimados fica cada vez mais próximo que o vetor de parâmetros verdadeiro.
- **Prova:**

$$\hat{\beta} = \beta + (X'X)^{-1}X'u = \beta + \left( \frac{1}{n} \sum_{i=1}^n (X_i X_i')^{-1} \right) \left( \frac{1}{n} \sum_{i=1}^n (X_i u_i) \right)$$

$$\implies \text{plim}(\hat{\beta}) = \beta + E[X_i X_i']^{-1} E[X_i u_i] = \beta, \text{ pois } E[X_i u_i] = 0$$

## CONSISTÊNCIA (2)

- ▶ Note que consistência depende da covariância entre regressores e termo de erro ser zero ( $E[X_i u_i] = 0$ ).
- ▶ Essa hipótese é implicada pela hipótese de média do termo de erro ser independente dos regressores ( $E[u_i | X_i] = 0$ ).
- ▶ Mas a recíproca não é verdadeira! (hipótese mais fraca)
- ▶ Consistência ( $\sim$  ausência de viés assintótico) depende de hipóteses mais fracas que ausência de viés.

# NORMALIDADE ASSINTÓTICA

- ▶ A distribuição de  $(\hat{\beta} - \beta)/\text{ep}(\hat{\beta})$  converge para uma distribuição  $N(0, 1)$ .
- ▶ Isso é uma aplicação do teorema central do limite.
  - Não depende de normalidade do termo de erro ( $u_i$ ).
  - Só precisamos de que média do erro seja zero e sua variância finita.
- ▶ **Implicação:** não precisamos impor normalidade para testar hipóteses em grandes amostras.

## O QUE OCORRE QUANDO $E[X_i u_i] \neq 0$ ?

- ▶ Hipótese  $E[X_i u_i] = 0$  é a principal hipótese de identificação do modelo de MQO.
- ▶ O que ocorre se ela falha?

$$\text{plim}(\hat{\beta}) = \beta + E[X_i X_i']^{-1} E[X_i u_i]$$

- ▶  $E[X_i u_i] \neq 0$  implica que  $\text{plim}(\hat{\beta}) \neq \beta$ 
  - $E[X_i u_i] > 0$ : MQO sobrestima parâmetro real
  - $E[X_i u_i] < 0$ : MQO subestima parâmetro real
- ▶ Três casos em que  $E[X_i u_i] \neq 0$ : viés de variável omitida, viés de simultaneidade e viés de atenuação.



# VIÉS DE VARIÁVEL OMITIDA (1)

- ▶ Hipótese  $E[X_i u_i] = 0$  é a hipótese de identificação do modelo de MQO.
- ▶ O que ocorre se ela falha? Considere o modelo:

$$y_i = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + u_i, E[x_{1i} u_i] = E[x_{2i} u_i] = 0$$

- ▶ Suponha que observamos  $x_1$ , mas não  $x_2$  e considere a regressão de  $y_i$  em  $x_{1i}$ .
- ▶ Defina  $\nu_i = \beta_2 x_{2i} + u_i$  e note que:

$$E[x_{1i} \nu_i] \neq 0$$

## VIÉS DE VARIÁVEL OMITIDA (2)

- Coeficiente da regressão de  $y_i$  em  $x_{1i}$  é:

$$\hat{\beta}_1 = \frac{cov(x_{1i}, y_i)}{var(x_{1i})}$$

- Temos:

$$\hat{\beta}_1 = \frac{cov(x_{1i}, \beta_1 x_{1i} + \beta_2 x_{2i} + u_i)}{var(x_{1i})} = \beta_1 + \beta_2 \frac{cov(x_{1i}, x_{2i})}{var(x_{1i})}$$

- Efeito de MQO é efeito real mais produto entre efeito da variável omitida sobre  $y$  e efeito de  $x_1$  em  $x_2$ .
- O viés que surge quando omitimos regressores relevantes é denominado viés de variável omitida.
- **Desafio:** garantir que não existem regressores relevantes não omitidos.

## EXEMPLO

- Relação entre  $y$  e os regressores  $x_1$  e  $x_2$  seja descrita pelo modelo populacional:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + u$$

- Relação entre  $x_1$  e  $x_2$  é descrita por:

$$x_2 = \alpha x_1 + \nu$$

- Suponha que os parâmetros populacionais sejam  $\beta_0 = 0.1$ ,  $\beta_1 = 0.6$ ,  $\beta_2 = 0.4$  e  $\alpha = 0.5$  e as distribuições  $u \sim N(0, 4)$ ,  $\nu \sim N(0, 16)$  e  $x_1 \sim N(0, 1)$ .

# REGRESSÃO LONGA

Simulo 10.000 observações dos vetores  $u$ ,  $v$ ,  $x_1$ ,  $x_2$  e  $y$ .

```
# Vetores #  
  
set.seed(1985)  
  
beta0 = 0.1  
beta1 = 0.6  
beta2 = 0.4  
alpha = 0.5  
  
u = rnorm(10000, mean = 0, sd = 2)  
v = rnorm(10000, mean = 0, sd = 4)  
x1 = rnorm(10000, mean = 0, sd = 1)  
x2 = alpha*x1+v  
  
y = beta0 + beta1*x1 + beta2*x2 + u  
  
dados = data.frame(cbind(y,x1,x2))
```

# REGRESSÃO LONGA

Rodo regressão longa.

```
# Regressão #  
  
full.model = lm_robust(y ~ x1 + x2, data = dados, se_type = "HC1")  
  
summary(full.model)
```

Standard error type: HC1

Coefficients:

	Estimate	Std. Error	t value	Pr(> t )	CI Lower	CI Upper	DF
(Intercept)	0.06576	0.019964	3.294	9.915e-04	0.02663	0.1049	9997
x1	0.61181	0.020065	30.491	2.504e-195	0.57248	0.6511	9997
x2	0.39489	0.005066	77.950	0.000e+00	0.38496	0.4048	9997

Multiple R-squared: 0.4366 , Adjusted R-squared: 0.4364

F-statistic: 3858 on 2 and 9997 DF, p-value: < 2.2e-16

# REGRESSÃO CURTA

Rodo regressão curta.

```
short.model = lm_robust(y ~ x1, data = dados, se_type = "HC1")
```

```
summary(short.model)
```

Standard error type: HC1

Coefficients:

	Estimate	Std. Error	t value	Pr(> t )	CI Lower	CI Upper	DF
(Intercept)	0.04258	0.02536	1.679	9.323e-02	-0.007139	0.0923	9998
x1	0.80015	0.02548	31.405	1.475e-206	0.750209	0.8501	9998

Multiple R-squared: 0.08995 , Adjusted R-squared: 0.08986

F-statistic: 986.3 on 1 and 9998 DF, p-value: < 2.2e-16

# VIÉS DE SIMULTANEIDADE (1)

- Considere o modelo de oferta e demanda:

$$\log Q_D = c_D + \epsilon_D \log P + X'_D \gamma_D + \varepsilon_D$$

$$\log P = c_S + \epsilon_S \log Q_S + X'_S \gamma_S + \varepsilon_S$$

$$\log Q^* = \log Q_D = \log Q_S$$

- Queremos estimar  $\epsilon_D$  (elasticidade-preço da demanda) e  $\epsilon_S$  (elasticidade preço da oferta).
- Note que:

$$\log Q = c_D + \epsilon_D(c_S + \epsilon_S \log Q + X'_S \gamma_S + \varepsilon_S) + X'_D \gamma_D + \varepsilon_D \implies E[\log Q \times \varepsilon_S] \neq 0$$

$$\log P = c_S + \epsilon_S(c_D + \epsilon_D \log P + X'_D \gamma_D + \varepsilon_D) + X'_S \gamma_S + \varepsilon_S \implies E[\log P \times \varepsilon_D] \neq 0$$

## VIÉS DE SIMULTANEIDADE (2)

- ▶ O modelo de oferta e demanda ilustra como a estimação de mínimos quadrados ordinários (MQO) falha quando existe simultaneidade ou causalidade reversa.
- ▶  $E[\log P \times \varepsilon_D] > 0$ : MQO vies a elasticidade-preço da demanda para cima (i.e., em direção a zero).
- ▶  $E[\log Q \times \varepsilon_S] < 0$ : MQO vies a elasticidade-preço da oferta para baixo (em direção a zero).
- ▶ **Exercício:** prove os fatos acima.



# VIÉS DE ATENUAÇÃO (1)

- Considere o modelo de regressão linear:

$$y_i = \alpha + \beta x_i + \varepsilon, E[\varepsilon|x_i] = 0$$

- Suponha que  $x_i$  não é observado e sim  $x_i^* = x_i + \nu_i$ . Modelo estimado é:

$$y_i = \alpha + \beta x_i^* + (-\beta \nu_i + \varepsilon)$$

- Defina  $\text{var}(x_i) = \sigma_x^2$ ,  $\text{var}(\varepsilon) = \sigma_u^2$ ,  $\text{var}(\nu_i) = \sigma_\nu^2$ . Temos:

$$\beta_{MQO} = \frac{\text{cov}(x_i^*, y_i)}{\text{var}(x_i^*)} = \frac{\text{cov}(x_i^*, \alpha + \beta x_i^* - \beta \nu_i + \varepsilon)}{\text{var}(x_i^*)}$$

$$= \beta - \beta \frac{\text{cov}(x_i + \nu_i, \nu_i)}{\text{var}(x_i + \nu_i)} = \beta - \beta \frac{\sigma_\nu^2}{\sigma_x^2 + \sigma_\nu^2} = \beta \left( \frac{\sigma_x^2}{\sigma_x^2 + \sigma_\nu^2} \right) < \beta$$

## VIÉS DE ATENUAÇÃO (2)

- Considere o seguinte modelo populacional:

$$y = \beta_0 + \beta_1 x + \varepsilon$$

- Suponha que não observamos  $x$  e sim  $x^* = x + \nu$ .
- Os parâmetros populacionais são  $\beta_0 = 1$  e  $\beta_1 = 0.6$
- $x$  tem distribuição  $N(0, 4)$
- Os termos de erro  $\nu$  e  $\varepsilon$  tem distribuições  $N(0, 1)$  e  $N(0, 16)$ , respectivamente.

# VIÉS DE ATENUAÇÃO (3)

Simulo 10.000 observações dos vetores  $u$ ,  $\nu$ ,  $x$ ,  $x^*$  e  $y$ .

```
# Vetores #  
  
set.seed(1985)  
  
beta0 = 1  
beta1 = 0.6  
  
x = rnorm(10000, mean = 0, sd = 2)  
v = rnorm(10000, mean = 0, sd = 1)  
u = rnorm(10000, mean = 0, sd = 4)  
  
y = beta0 + beta1*x + u  
  
xs = x + v  
  
dados = data.frame(cbind(y,x,xs))
```

# VIÉS DE ATENUAÇÃO (4)

Viés de atenuação:  $\sigma_x^2 / (\sigma_x^2 + \sigma_v^2) \times \beta = 0.8 \times 0.6 = 0.48$

```
# Vetores #  
library(estimatr)  
summary(lm_robust(y ~ x, data = dados))  
  
Coefficients:  
      Estimate Std. Error t value Pr(>|t|) CI Lower CI Upper DF  
(Intercept)  1.0367    0.03987   26.01 2.520e-144   0.9586   1.1149 9998  
x            0.6093    0.01986   30.68 1.129e-197   0.5704   0.6483 9998  
  
Multiple R-squared:  0.08515 , Adjusted R-squared:  0.08506  
F-statistic: 941.5 on 1 and 9998 DF, p-value: < 2.2e-16  
  
summary(lm_robust(y ~ xs, data = dados))  
  
Coefficients:  
      Estimate Std. Error t value Pr(>|t|) CI Lower CI Upper DF  
(Intercept)  1.0397    0.04027   25.82 2.231e-142   0.9608   1.1186 9998  
xs           0.4857    0.01817   26.73 4.293e-152   0.4501   0.5213 9998  
  
Multiple R-squared:  0.0669 , Adjusted R-squared:  0.06681  
F-statistic: 714.5 on 1 and 9998 DF, p-value: < 2.2e-16
```