

Mestrado Profissional em Avaliação e  
Monitoramento de Políticas Públicas

# Métodos Quantitativos I

## Aula 9: Modelos em Pannel: tópicos avançados

---

Professores: Daniel Grimaldi e Arthur Bragança

3º Trimestre - 2025

# Efeitos Aleatórios (RE)

# RE vs FE

- Podemos pensar no FE como um modelo em que o intercepto varia livremente entre os indivíduos - conforme  $\alpha_i$  na Equação (1).

$$y_{it} = \alpha_i + \beta_1 x_{it}^1 + \epsilon_{it} \quad (1)$$

- Na prática, ao não impormos nenhuma restrição sobre o PGD de  $\alpha_i$ , **ganhamos robustez ao custo de eficiência estatística.**
  - Dependendo do painel, cada  $\alpha_i$  será estimado com algumas poucas observações, o que reduz a precisão das estimativas.

# RE vs FE

- ❖ O modelo de efeitos aleatórios (RE) também assume que os interceptos são diferentes entre os indivíduos, mas assume que:
  - ❖ o PGD de  $\alpha_i$  e equivale a uma distribuição aleatória conhecida - por exemplo, todos vêm de uma distribuição Normal; e
  - ❖ essa heterogeneidade não está correlacionada com as demais variáveis dependentes -  $E[\alpha_i X_{it}] = 0$ .
- ❖ Isso aumenta a precisão das estimativas, mas produz estimativas viesadas se o  $E[\alpha_i X_{it}] \neq 0$

# Modelagem de um RE

- Podemos pensar em um caso em que  $\alpha_i = \alpha_0 + v_i$ , sendo que  $v_i \sim N(0, 1)$ , conforme Equação (2)

$$\begin{aligned}y_{it} &= \alpha_i + \beta_1 x_{it}^1 + \epsilon_{it} \\&= \alpha_0 + \beta_1 x_{it}^1 + v_i + \epsilon_{it} \\&= \alpha_0 + \beta_1 x_{it}^1 + \eta_{it}\end{aligned}\tag{2}$$

- Neste caso, a omissão de  $v_i$  do modelo de regressão leva a perda de eficiência por autocorrelação dos resíduos (existente entre distintas observações de um mesmo indivíduo), mas não produz viés.

# RE como Mínimos Quadrados Ponderados

- Em um contexto de painel, um (pooled) MQO assume que:

$$E[\eta_{it}\eta_{js}] = \begin{cases} \sigma_{\eta}^2; & \text{se } i = j \wedge t = s \\ 0; & \text{cc.} \end{cases} \quad (3)$$

# RE como Mínimos Quadrados Ponderados

- ❖ O modelo RE estima a Equação (2) por meio de Mínimos Quadrados Ponderados assumindo uma matriz de variância robusta à autocorrelação, de tal forma que:

$$E[\eta_{it}\eta_{js}] = \begin{cases} \sigma_{\epsilon}^2 + \sigma_v^2; & \text{se } i = j \wedge t = s \\ \sigma_v^2; & \text{se } i = j \wedge t \neq s \\ 0; & \text{cc.} \end{cases} \quad (4)$$

- ❖ Ao ajustarmos a estrutura imposta à matriz de covariância, conseguimos uma estimativa mais precisa.

# Extensões de FE



# Múltiplos efeitos fixos

- ❖ Vimos até agora apenas o caso em que incluímos um efeito fixo (indivíduos), mas um modelo em painel pode ser estimado com múltiplos efeitos fixos, desde exista grau de liberdade (variância) para múltiplas categorias:
  - ❖ Por exemplo, se no painel temos diferentes categorias de gênero em diferentes municípios, podemos incluir um efeito de gênero e outro de município
- ❖ Contudo, não é possível incluir simultaneamente um efeito fixo de município e outro de UF, pois não há variância de UFs dentro de um mesmo município.
  - ❖ Neste caso, a inclusão do efeito fixo de município já controla por efeitos de UFs.

# Two-way Fixed Effects (TWFE)

- ❖ O TWFE é um caso particular de estimação em painel com múltiplos efeitos fixos. Mais especificamente, o TWFE inclui efeitos fixos para indivíduos ( $\alpha_i$ ) e para períodos de tempo ( $\alpha_t$ )
- ❖ Podemos pensar nesse modelo como uma sequência de transformações within (a ordem não importa), onde controlamos por fatores não observados que afetaram os diferentes indivíduos (sem variar no tempo) e os diferentes períodos de tempo (sem variar entre indivíduos).

O Diferenças-em-diferenças canônico (DiD) pode ser representado pela Equação (5), onde  $T_i$  e  $P_t$  representam dummies que, identificam respectivamente, indivíduos tratados e períodos após o tratamento.

$$y_{it} = \alpha + T_i + P_t + T_i P_t + \epsilon_{it} \quad (5)$$

- Note que esse modelo pode ser pensado como um caso particular de TWFE, com efeitos fixos para indivíduos tratados ( $T_i = 1$ ) e períodos posteriores ao tratamento ( $P_t = 1$ )

# Hands on

# Caso Geral

- ✚ Vamos partir do mesmo exemplo da aula 8
- ✚ Ainda temos um painel de  $i$  municípios acompanhados por  $t$  anos e queremos estimar o efeito de uma política pública de facilitação de acesso a armas ( $P$ ) sobre o nível de segurança pública - medido por um índice de morte violentas anuais por 100 mil habitantes ( $Y_{it}$ )
- ✚ Mas faremos alguns ajustes para tornar o PGD um pouco mais flexível...
- ✚ ... e vamos **entender como mudanças nos parâmetros do PGD afetam estimativas de MQO, FE e RE.**

# PGD: Formação de $y_{it}$

$$\alpha_i \sim N(0, 2); \alpha_{it} = \alpha_i (1 + \theta_1)^t \quad (6)$$

$$\gamma_0 \sim N(0, 2); \gamma_t = \gamma_0 (1 + \theta_2)^t + v^3 t \quad (7)$$

$$x_i^1 \sim N(7, 0.5); x_{it}^1 = x_i^1 + v_{it}^1 \quad (8)$$

$$x_i^2 \sim N(40, 10); x_{it}^2 = x_i^2 + v_{it}^2 \quad (9)$$

$$y_{it} = \alpha_{it} + \gamma_t + \beta_1 x_{it}^1 + \beta_2 x_{it}^2 + \delta P_{it} \epsilon_{it} \quad (10)$$

$$v_{it}^1 \sim N(0, 1); v_{it}^2 \sim N(0, 5); v_t^3 \sim N(0, 1); \epsilon_{it} \sim N(0, 1) \quad (11)$$

# PGD: Adesão a $P$

O acesso à política  $P$  é definido pelas equações (13) a (15).

$$S_i = \frac{1}{1 + e^{g(\alpha_{it})}} \quad (12)$$

$$g(\alpha_{it}) = 0 + \zeta\left(\sum_T \alpha_{it} - \mu_\alpha\right) \quad (13)$$

$$P_i \sim \text{Bern}(S_i) \quad (14)$$

$P_{it}$  assume valores 0 ou 1, a depender da realização de uma Bernoulli com probabilidade de sucesso  $S_i$ . **Por simplificação, todos os indivíduos que têm acesso à política, começam a receber o tratamento no mesmo período  $t_p = \frac{T}{2}$ .**

## Caso 1: $\alpha_i$ não afeta acesso

- ❖ Neste primeiro caso  $\alpha_{it} = \alpha_i \forall t$  e o acesso à política não é determinado por ele.
  - ❖  $\theta_1 = 0$  e  $\zeta = 0$
- ❖ Os efeitos fixos de tempo são aleatórios:
  - ❖  $\theta_2 = 0$
- ❖ O impacto da política segue sendo negativo sobre os índices de criminalidade
  - ❖  $\delta = 1$
- ❖ Além disso:  $\beta_1 = 0.5$  e  $\beta_2 = 0.1$
- ❖ Qual é o modelo mais adequado?



# Implementando o PGD - caso 1

Como de costume, escrevemos uma função (denominada `pgd.R` para simular esse PGD.

```
source("pgd.R")
set.seed(1)
data1 <- pgd(n.id=5570, n.t=6, beta=c(0.5, 0.1),
             delta=1, mu_x=c(7, 40),
             sigma_x=c(0.5, 10), mu_alpha=0,
             sigma_alpha=2, theta_1=0, theta_2=0,
             zeta=0)
```

# Estimando os modelos - caso 1

```
require(plm)
data.reg <- data1 %>%
  plm.data(index=c("id", "t"))

reg_ols <- plm(y ~ x1 + x2 + P,
               model="pooling", data=data.reg)
reg_fe <- plm(y ~ x1 + x2 + P,
               model="within", data=data.reg)
reg_twfe <- plm(y ~ x1 + x2 + P,
                 model="within",
                 effects="twoways", data=data.reg)
reg_re <- plm(y ~ x1 + x2 + P,
               model="random", data=data.reg)
```

# Resultados - caso 1

	<i>Dependent variable:</i>			
	<i>y</i>			
	OLS (1)	FE (2)	TWFE (3)	RE (4)
x1	0.4944*** (0.0098)	0.4969*** (0.0059)	0.4969*** (0.0059)	0.4967*** (0.0059)
x2	0.1019*** (0.0021)	0.0993*** (0.0012)	0.0993*** (0.0012)	0.0995*** (0.0012)
P	0.9648*** (0.0283)	1.0036*** (0.0157)	1.0036*** (0.0157)	1.0013*** (0.0155)
Constant	2.4826*** (0.1079)			2.5526*** (0.0686)
Observations	33,420	33,420	33,420	33,420
R <sup>2</sup>	0.1557	0.3900	0.3900	0.3541

*Note:*

\*p<0.1; \*\*p<0.05; \*\*\*p<0.01

# Usando LGN


```
get_models <- function(i){  
  set.seed(i)  
  data <- pgd(n.id=5570, n.t=6, beta=c(0.5, 0.1),  
             delta=1, mu_x=c(7, 40),  
             sigma_x=c(0.5, 10), mu_alpha=0,  
             sigma_alpha=2, theta_1=0, theta_2=0,  
             zeta=0)  
  ols <- plm(y ~ x1+ x2 + P, data=data, model="pooling")  
  fe <- plm(y ~ x1+ x2 + P, data=data, model="within")  
  twfe <- plm(y ~ x1+ x2 + P, data=data, effect = "twoways",  
             model="within")  
  re <- plm(y ~ x1+ x2 + P, data=data, model="random")  
  output <- data.frame(sample=i,  
                       ols = ols$coefficients["P"],  
                       fe = fe$coefficients["P"],  
                       twfe = twfe$coefficients["P"],  
                       re = re$coefficients["P"])}  
}
```

# Usando LGN

```
lgn.data <- lapply(1:50, get_models) %>%  
  rbindlist()  
head(lgn.data)
```

##	sample	ols	fe	twfe	re
##	<int>	<num>	<num>	<num>	<num>
## 1:	1	0.9647760	1.0036094	0.9871174	1.0012553
## 2:	2	1.0064966	1.0016655	1.0010830	1.0019593
## 3:	3	0.9942945	0.9947921	1.0225309	0.9947754
## 4:	4	0.9898379	0.9871762	0.9889057	0.9873263
## 5:	5	0.9654242	0.9901807	0.9758573	0.9887580
## 6:	6	0.9658109	0.9571945	0.9417144	0.9576901

### *Distribuição dos coeficientes de P*



Modelo fe ols re twfe

## Caso 2: $\alpha_i$ afeta acesso

- Neste segundo caso  $\alpha_{it} = \alpha_i \forall t$  e o acesso à política é fortemente influenciado por ele.
  - $\theta_1 = 0$  e  $\zeta = 1$
- Os demais parâmetros seguem os mesmos: qual é o modelo mais adequado?

# Implementando o PGD - caso 2

```
set.seed(13)
data2 <- pgd(n.id=5570, n.t=6, beta=c(0.5, 0.1),
             delta=1, mu_x=c(7, 40),
             sigma_x=c(0.5, 10), mu_alpha=0,
             sigma_alpha=2, theta_1=0, theta_2=0,
             zeta=1)
```




# Resultados - caso 2

	<i>Dependent variable:</i>			
	<i>y</i>			
	OLS (1)	FE (2)	TWFE (3)	RE (4)
x1	0.4878*** (0.0096)	0.5013*** (0.0060)	0.5013*** (0.0060)	0.4993*** (0.0061)
x2	0.0994*** (0.0020)	0.1002*** (0.0012)	0.1002*** (0.0012)	0.1001*** (0.0012)
P	-0.6895*** (0.0272)	1.0039*** (0.0154)	1.0039*** (0.0154)	0.8548*** (0.0159)
Constant	2.9412*** (0.1058)			2.4460*** (0.0694)
Observations	33,420	33,420	33,420	33,420
R <sup>2</sup>	0.1437	0.3963	0.3963	0.3266

*Note:*

\*p<0.1; \*\*p<0.05; \*\*\*p<0.01

### *Distribuição dos coeficientes de P*



# Caso 3: Tendência temporal

- ❖ Neste segundo caso  $\alpha_{it} = \alpha_i \forall t$  e o acesso à política é fortemente influenciado por ele.
  - ❖  $\theta_1 = 0$  e  $\zeta = 1$
- ❖ Além disso, há uma tendência temporal, de tal forma que  $\gamma_t$  cresce, em módulo, com o tempo.
  - ❖  $\theta_2 = 0.25$  e  $\zeta = 1$
- ❖ Os demais parâmetros seguem os mesmos: qual é o modelo mais adequado?

# Implementando o PGD - caso 3

```
set.seed(13)
data3 <- pgd(n.id=5570, n.t=6, beta=c(0.5, 0.1),
             delta=1, mu_x=c(7, 40),
             sigma_x=c(0.5, 10), mu_alpha=0,
             sigma_alpha=2, theta_1=0, theta_2=0.25,
             zeta=1)
```


# Resultados - caso 3

	<i>Dependent variable:</i>			
	<i>y</i>			
	OLS (1)	FE (2)	TWFE (3)	RE (4)
x1	0.4944*** (0.0098)	0.4969*** (0.0059)	0.4969*** (0.0059)	0.4967*** (0.0059)
x2	0.1019*** (0.0021)	0.0993*** (0.0012)	0.0993*** (0.0012)	0.0995*** (0.0012)
P	0.9648*** (0.0283)	1.0036*** (0.0157)	1.0036*** (0.0157)	1.0013*** (0.0155)
Constant	2.4826*** (0.1079)			2.5526*** (0.0686)
Observations	33,420	33,420	33,420	33,420
R <sup>2</sup>	0.1557	0.3900	0.3900	0.3541

*Note:*

\*p<0.1; \*\*p<0.05; \*\*\*p<0.01

### *Distribuição dos coeficientes de P*



# Caso 4: Tendências distintas

- ❖ Neste segundo caso  $\alpha_{it} = \alpha_i \forall t$  e o acesso à política é fortemente influenciado por ele.
  - ❖  $\theta_1 = 0$  e  $\zeta = 1$
- ❖ Além disso, há uma tendência temporal em  $\alpha_i t$ , de tal forma que  $\alpha_t$  cresce, em módulo, com o tempo.
  - ❖  $\theta_1 = 0.25$  e  $\zeta = 1$
- ❖ Os demais parâmetros seguem os mesmos do caso 3: qual é o modelo mais adequado?

# Implementando o PGD - caso 4

```
set.seed(13)
data4 <- pgd(n.id=5570, n.t=6, beta=c(0.5, 0.1),
             delta=1, mu_x=c(7, 40),
             sigma_x=c(0.5, 10), mu_alpha=0,
             sigma_alpha=2, theta_1=0.25, theta_2=0.25,
             zeta=1)
```




# Resultados - caso 4

	<i>Dependent variable:</i>			
	<i>y</i>			
	OLS (1)	FE (2)	TWFE (3)	RE (4)
x1	0.4852*** (0.0198)	0.5081*** (0.0121)	0.5081*** (0.0121)	0.5034*** (0.0126)
x2	0.0974*** (0.0041)	0.0982*** (0.0024)	0.0982*** (0.0024)	0.0981*** (0.0025)
P	-5.3723*** (0.0560)	-1.3311*** (0.0311)	-1.3311*** (0.0311)	-1.7226*** (0.0328)
Constant	21.0874*** (0.2175)			20.0135*** (0.1423)
Observations	33,420	33,420	33,420	33,420
R <sup>2</sup>	0.2356	0.1584	0.1584	0.1488

*Note:*

\*p<0.1; \*\*p<0.05; \*\*\*p<0.01

## Distribuição dos coeficientes de P



# O que aconteceu?


- ❖ No caso 4,  $\alpha_{it}$  varia ao longo do tempo de tal forma que os indivíduos estão em trajetórias diferentes.
- ❖ Tal qual no caso do DiD, um painel de efeitos fixos depende da hipótese de que as variações within (“tendência”) dos indivíduos controle são uma boa referência para a trajetória dos indivíduos tratados.
  - ❖ se  $\alpha_{it}$  varia no tempo de maneira distinta entre tratados e controles, então isso não vale.
- ❖ Por isso, quando vamos usar TWFE, DiD ou mesmo painel de efeitos fixos para avaliar impacto de políticas, precisamos avaliar a validade da hipótese de tendências paralelas.

# Tendências paralelas - caso 3

```
data.temp <- data3 %>%  
  group_by(D, t) %>%  
  summarise(y = mean(y)) %>%  
  mutate(grupo = case_when(D==1 ~ "tratado",  
                             D==0 ~ "controle"))
```

## *Evolução da média de y por grupo de tratamento*

**Caso 3**



## *Evolução da média de y por grupo de tratamento*

### *Caso 4*

